



AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE

WYDZIAŁ GEOLOGII, GEOFIZYKI I OCHRONY ŚRODOWISKA

KATEDRA GEOINFORMATYKI I INFORMATYKI STOSOWANEJ

Projekt dyplomowy

*Badanie możliwości predykcyjnych algorytmów uczenia maszynowego
w kontekście popularności utworów muzycznych*

*Exploring the predictive capabilities of machine learning algorithms in
the context of music popularity*

Autor:

Natalia Klinik

Kierunek studiów:

Inżynieria i Analiza Danych

Opiekun pracy:

dr inż. Magdalena Habrat

Kraków, 2026

*Serdecznie dziękuję mojej promotorce,
pani dr inż. Magdalenie Habrat, za pomoc,
zaangażowanie oraz ciągłą i szybką komunikację;
rodzinie i przyjaciołom za nieustanne wsparcie
i niezachwianą wiarę w moje możliwości;
Weronice Jopek, dzięki której wiem, że w każdym
środowisku można znaleźć swoich ludzi;
a przede wszystkim – **Pawłowi Kocurowi** –
bez którego prawdopodobnie poddałabym się po
pierwszej poniesionej porażce.*

Streszczenie

W dobie streamingu muzyki przewidywanie popularności utworów muzycznych stanowi złożone zadanie analityczne, wykraczające poza subiektywne opinie ekspertów. Celem niniejszego projektu była analiza wpływu cech sygnałowych (takich jak głośność, tonacja czy metrum) na sukces komercyjny utworu. Problem badawczy zdefiniowano dwutorowo: jako zadanie klasyfikacji oraz regresji, wykorzystując do tego algorytmy uczenia nadzorowanego. Najlepsze wyniki osiągnięto przy użyciu modeli opartych na drzewach decyzyjnych. *Random Forest Classifier* uzyskał w zadaniu klasyfikacji wynik $F1 = 0.5782$, a w problemie regresyjnym *Random Forest Regressor* osiągnął współczynnik $R^2 = 0.3245$. Mimo strojenia hiperparametrów i zastosowania metod zespołowych, nie odnotowano istotnej poprawy jakości predykcji. Otrzymane rezultaty wskazują, że fizyczne cechy dźwięku nie są wystarczającym predyktorem popularności, co potwierdza potrzebę rozszerzenia problemu o aspekty socjologiczne, marketigowe oraz analizę trendów medialnych.

Słowa kluczowe: popularność muzyki, uczenie maszynowe, Million Song Dataset, uczenie nadzorowane, klasyfikacja, regresja

Abstract

In the era of music streaming, predicting the popularity of music tracks is a complex analytical task that goes beyond the subjective experts' opinions. The aim of this project was to analyze the impact of audio signal characteristics (such as loudness, key, mode) on the commercial success of a track. The research problem was defined in two ways: as a classification and regression task, using supervised learning algorithms. The best results were achieved using models based on decision trees. The Random Forest Classifier achieved a result of $F1 = 0.5782$ in the classification task, and in the regression problem, the Random Forest Regressor achieved a coefficient of $R^2 = 0.3245$. Despite hyperparameter tuning and the use of ensemble methods, no significant improvement in prediction quality was observed. The results indicate that physical sound characteristics are not a sufficient popularity predictor, confirming the need to extend the problem to include sociological and marketing aspects as well as media trend analysis.

Keywords: music popularity, machine learning, Million Song Dataset, supervised learning, classification, regression

Spis treści

1. Wprowadzenie	9
1.1. Dotychczasowe badania – dane z serwisu Spotify	9
1.2. Ograniczenia licencyjne platformy Spotify	10
1.3. Alternatywny zbiór danych – Million Song Dataset	10
1.4. Cele pracy	11
1.5. Struktura pracy	11
2. Uczenie maszynowe i algorytmy predykcyjne	12
2.1. Uczenie maszynowe	12
2.2. Regresja Liniowa	13
2.2.1. Regresja liniowa prosta	13
2.2.2. Regresja wieloraka	13
2.3. Regresja Logistyczna	14
2.3.1. Model binarny	14
2.3.2. Model wieloklasowy	14
2.4. Drzewa Decyzyjne i Las Losowy	15
2.4.1. Drzewa Decyzyjne	15
2.4.2. Las Losowy	15
2.5. Wzmacnianie Gradientowe	16
2.6. Maszyny Wektorów Nośnych	17
2.6.1. Działanie algorytmu	17
2.6.2. Problemy nieseparowalne liniowo	18
2.6.3. Klasyfikacja nieliniowa i problemy wieloklasowe	18
2.7. Sztuczne Sieci Neuronowe	19
2.7.1. Budowa biologicznego i sztucznego neuronu	19
2.7.2. Budowa sztucznej sieci neuronowej	19
2.7.3. Proces uczenia się sieci neuronowej	21
2.8. Ocena skuteczności modeli	21

2.8.1. Metryki modeli klasyfikacyjnych.....	21
2.8.2. Metryki modeli regresyjnych.....	22
3. Metodyka	24
3.1. Środowisko programistyczne i wykorzystane narzędzia.....	24
3.2. Dane źródłowe	25
3.3. Ekstrakcja danych i wstępna inżynieria cech	25
3.3.1. Przetwarzanie wstępne i selekcja atrybutów.....	25
3.3.2. Agregacja cech wektorowych	25
3.3.3. Cechy tekstowe i czasowe.....	26
3.4. Eksploracyjna analiza danych (EDA).....	26
3.4.1. Analiza zmiennej objaśnianej	26
3.4.2. Rozkłady zmiennych objaśniających	27
3.4.3. Analiza korelacji i redukcja nadmiarowości	32
3.5. Preprocessing.....	33
3.5.1. Obsługa brakujących danych	33
3.5.2. One-Hot-Encoding.....	34
3.5.3. Podział danych na zbiór treningowy i testowy	34
3.6. Trenowanie modeli	35
3.6.1. Problem klasyfikacyjny.....	35
3.6.2. Problem regresyjny	35
3.7. Ocena skuteczności modeli	36
4. Wyniki badań	37
4.1. Wyniki problemu klasyfikacyjnego	37
4.2. Wyniki problemu regresyjnego.....	38
4.3. Zastosowanie metod zespołowych	39
4.4. Analiza przeuczenia modeli	40
4.5. Strojenie hiperparametrów	41
4.5.1. Wyniki optymalizacji	42
4.6. Analiza istotności cech	43
4.7. Ostateczna ocena jakości predykcji.....	46
4.7.1. Porównanie macierzy pomyłek.....	46
4.7.2. Analiza błędów regresji	47
4.8. Ostateczna ocena metryk modeli.....	48
5. Dyskusja.....	50

5.1.	Wyzwania związane z pozyskiwaniem i jakością danych	50
5.1.1.	Ograniczenia platformy Spotify.....	50
5.1.2.	Problematyka zbioru <i>Million Song Dataset</i>	50
5.2.	Niezbalansowanie klas a specyfika rynku	51
5.3.	Interpretacja wyników modelowania.....	51
5.4.	Dominacja artysty.....	51
5.5.	Rola czynników kontekstowych i socjologicznych.....	51
5.5.1.	Ekspozycja medialna	52
5.5.2.	Analiza tekstowa i sentyment	52
5.5.3.	Media społecznościowe	52
5.6.	Wnioski.....	52
6.	Podsumowanie	53
	Bibliografia	55
A.	Powiększone wizualizacje macierzy korelacji	59

1. Wprowadzenie

W ostatnich latach sposób dystrybucji muzyki uległ radykalnej transformacji. Jak wskazuje raport *IFPI Global Music Report 2024*, usługi cyfrowe odpowiadają obecnie za ponad 67% globalnych przychodów branży [1], wypierając tradycyjne nośniki fizyczne, takie jak płyty winylowe czy CD. Platformy streamingowe, takie jak Spotify czy YouTube Music dominują rynek, zapewniając użytkownikom nieograniczony i natychmiastowy dostęp do muzyki, bez konieczności gromadzenia danych na lokalnych nośnikach.

Szacowanie potencjału komercyjnego utworów wciąż pozostaje kluczowym elementem strategii wydawniczej, jednak przy obecnym wolumenie danych tradycyjne metody, takie jak badania na grupach fokusowych czy manualna analiza list przebojów, stają się nieefektywne. Systemy wiodących platform streamingowych przetwarzają dziennie około 1.4 biliona punktów danych [2]. Przekracza to możliwości analityczne człowieka, wymuszając zastosowanie zautomatyzowanych metod przetwarzania danych oraz algorytmów uczenia maszynowego.

1.1. Dotychczasowe badania – dane z serwisu Spotify

W literaturze przedmiotu dominuje podejście wykorzystujące interfejsy programistyczne (API) serwisu Spotify do pozyskania danych muzycznych. Badacze wielokrotnie udowadniali, że metadane akustyczne udostępniane przez platformę posiadają istotną wartość predykcyjną.

Gao [3] wykonała analizę eksploracyjną metadanych akustycznych, by następnie porównać działanie różnych modeli uczenia maszynowego. W swoich badaniach przetestowała modele regresji liniowej wielu zmiennych, regresji logistycznej, drzew decyzyjnych, lasu losowego, wzmacnianych drzew decyzyjnych oraz sieci neuronowych. Eksperymenty wykazały, że modele uczenia maszynowego są zdolne do przewidzenia popularności utworów muzycznych. Jako grupę najskuteczniejszych narzędzi autorka wskazała wzmacniane drzewa decyzyjne, lasy losowe oraz sieci neuronowe. Modele te pozwoliły na przewidywanie popularności piosenek z wysoką skutecznością, osiągając miarę F1 na poziomie 0.83.

W pracy Jiang [4], porównano skuteczność trzech modeli regresyjnych: prostej regresji liniowej, regresji lasu losowego oraz maszyn wzmacniania gradientowego. Badanie dowiodło, że model regresji lasu losowego najlepiej uchwycił nieliniowe zależności, osiągając najwyższy współczynnik determinacji R^2 . Autor wskazał taneczność (ang. *danceability*), energię oraz głośność jako kluczowe cechy świadczące o popularności utworu, zaznaczając, że do bardziej wnikliwych analiz konieczne jest uwzględnienie

czynników zewnętrznych, takich jak obecność piosenki w mediach społecznościowych czy działania marketingowe.

Araujo i in. [5] zbadali relację między popularnością utworu a zjawiskiem „wiralowości”. Badacze postawili pytanie, czy obecność utworu na liście *Virals*, a co za tym idzie – nagły wzrost zainteresowania nim – determinuje jego długoterminowy sukces (obecność na liście *Most-Popular*. Badanie zostało przedstawione jako problem klasyfikacyjny rozwiązany przy użyciu maszyny wektorów nośnych (SVM). Wyniki eksperymentu potwierdziły, że dane historyczne (rankingi przebojów) są wystarczającym predyktorem przyszłych trendów, pozwalając osiągnąć skuteczność modelu na poziomie przewyższającym 90% (miara F1).

Interesujące podejście zaprezentowali Yee i Raheem [6], którzy w procesie przewidywania popularności utworu, połączyli analizę cech akustycznych z platformy Spotify z analizą metryk społecznych z platformy YouTube. Autorzy rozpatrzyli problem klasyfikacyjny, przypisując utworom jeden z trzech stanów popularności (niska, średnia, wysoka). Najskuteczniejszym modelem okazał się być algorytm lasu losowego, osiągający dokładność bliską 80%. W badaniu odnotowano również, że dodanie zmiennych społecznościowych poprawiło wyniki modelu od 10% do 60% względem analizy opartej wyłącznie na zmiennych akustycznych.

Podobne wnioski przedstawili Pareek i współpracownicy [7], wykorzystując dane akustyczne do analizy potencjału komercyjnego utworu przed jego premierą. W badaniu porównali wyniki algorytmów lasu losowego, k-najbliższych sąsiadów oraz klasyfikator maszyny wektorów nośnych. Również w tym badaniu, autorzy wskazali najwyższą skuteczność modelu lasu losowego, który znacząco przewyższył pozostałe modele pod względem dokładności, precyzji oraz miary F1.

1.2. Ograniczenia licencyjne platformy Spotify

Mimo bogatej literatury opartej na danych pochodzących z API Spotify, kontynuacja podobnych badań napotyka obecnie bariery prawne. W odpowiedzi na dynamiczny rozwój generatywnej sztucznej inteligencji, firma wprowadziła restrykcyjne zmiany w regulaminie serwisu *Spotify for Developers*, całkowicie zakazując korzystania ze swoich danych do trenowania modeli uczenia maszynowego. 15 maja 2025 roku weszły w życie zapisy, które zabraniają „wykorzystywania platformy Spotify lub jakichkolwiek treści Spotify do trenowania modeli uczenia maszynowego lub sztucznej inteligencji lub w inny sposób wprowadzania treści Spotify do modeli uczenia maszynowego lub sztucznej inteligencji” [8].

1.3. Alternatywny zbiór danych – Million Song Dataset

W świetle wprowadzonych restrykcji prawnych, w niniejszej pracy zdecydowano się na wykorzystanie alternatywnego, otwartoźródłowego zestawu danych – *Million Song Dataset*. Jest to stworzona w 2011 roku kolekcja cech audio oraz metadanych miliona współczesnych utworów muzycznych [9].

Ze względu na wolumen dostępnych danych oraz liczne pliki uzupełniające, zbiór ten stanowi reprezentatywny materiał badawczy, umożliwiający przeprowadzenie założonych eksperymentów bez naruszania praw autorskich i licencyjnych.

1.4. Cele pracy

Głównym celem poniższej pracy jest zbadanie możliwości predykcyjnych algorytmów uczenia maszynowego w zadaniu prognozowania popularności utworów muzycznych na podstawie zbioru *Million Song Dataset* oraz zweryfikowanie w jakim stopniu surowe dane akustyczne oraz metadane artysty pozwalają na skuteczną predykcję sukcesu komercyjnego utworu. Realizacja celu zakłada przygotowanie danych, analizę porównawczą problemu regresyjnego i klasyfikacyjnego, ewaluację poszczególnych modeli oraz ich późniejszą optymalizację.

1.5. Struktura pracy

W **Rozdziale 1** nakreślono tło problemu badawczego oraz przedstawiono przegląd dotychczasowych badań (1.1). Uzasadniono również wybór zbioru danych (1.3) w oparciu o ograniczenia licencyjne platformy Spotify (1.2).

Rozdział 2 stanowi wprowadzenie teoretyczne. Przybliżono w nim pojęcie uczenia maszynowego (2.1) oraz charakterystykę poszczególnych algorytmów wykorzystanych w dalszych eksperymentach: regresji liniowej (2.2) i logistycznej (2.3), drzew decyzyjnych i lasu losowego (2.4), maszyn wektorów nośnych (2.6), wzmocniania gradientowego (2.5) oraz sieci neuronowych (2.7). Zdefiniowano również metryki służące do oceny jakości modeli (2.8).

Rozdział 3 poświęcono metodyce badań. Opisano w nim dane źródłowe (3.2), proces ich ekstrakcji i inżynierii (3.3), ich eksploracyjną analizę (3.4) oraz preprocessing (3.5). Przedstawiono także techniczne aspekty trenowania modeli (3.6) oraz sposoby ich walidacji (3.7).

W **Rozdziale 4** omówiono wyniki uzyskane przez podstawowe modele klasyfikacyjne (4.1) oraz regresyjne (4.2). Zaprezentowano zastosowane metody zespołowe (4.3), zjawisko przeuczania modeli (4.4) oraz metodykę strojenia hiperparametrów (4.5). Przeanalizowano również istotność cech w poszczególnych modelach (4.6). Na koniec przedstawiono ostateczne zestawienie jakości predykcji (4.7) oraz metryk (4.8) dla obu grup modeli.

Rozdział 5 traktuje o napotkanych ograniczeniach prawnych (5.1.1) oraz problematyce zbioru *MSD* (5.1.2). Opisano w nim również niezbalansowanie datasetu w kontekście specyfiki rynku (5.2) oraz zinterpretowano wyniki modelowania (5.3). Zaznaczono istotną dominację artysty (5.4), przybliżono rolę czynników socjologicznych (5.5) oraz wysnuto ogólne wnioski (5.6).

Rozdział 6 stanowi podsumowanie przeprowadzonych badań oraz syntezę wniosków końcowych.

2. Uczenie maszynowe i algorytmy predykcyjne

W przypadku dużych zbiorów danych, badanie możliwości predykcyjnych wymaga zastosowania zaawansowanych metod analitycznych, zdolnych do automatycznego wykrywania złożonych zależności. W tym kontekście, naturalnym narzędziem są metody uczenia maszynowego, które umożliwiają budowę modeli prognozujących popularność utworów na podstawie ich metadanych i cech akustycznych. Poniższy rozdział przybliży teoretyczne podstawy algorytmów wykorzystanych w dalszej części projektu.

2.1. Uczenie maszynowe

Uczenie maszynowe (ang. *Machine Learning*, ML) to dziedzina informatyki, zajmująca się tworzeniem algorytmów, które automatycznie poprawiają swoje działanie wraz z nabytym doświadczeniem [10]. W procesie budowy modelu, zadany zbiór danych dzieli się zazwyczaj na część treningową, służącą do estymacji parametrów, oraz testową, na której weryfikuje się skuteczność działania algorytmu [11].

Główne poddziedziny uczenia maszynowego obejmują uczenie nadzorowane (ang. *Supervised Learning*), nienadzorowane (ang. *Unsupervised Learning*) oraz uczenie ze wzmocnieniem (ang. *Reinforcement Learning*). Uczenie nadzorowane polega na trenowaniu modelu na podstawie uprzednio etykietowanych danych (wzorcowych rozwiązań). Jego celem jest odwzorowanie funkcji określającej relację między danymi wejściowymi i wyjściowymi. W przypadku uczenia nienadzorowanego operuje się na danych nieetykietowanych, a zadaniem algorytmu jest samodzielne wykrycie wzorców w zbiorze [11]. Natomiast uczenie ze wzmocnieniem polega na znalezieniu odpowiednich decyzji, które należy podjąć w danym środowisku i sytuacji, aby zmaksymalizować nagrodę [12].

W ramach nadzorowanego uczenia maszynowego wyróżnia się problemy regresji i klasyfikacji. Zadania, których celem jest przypisanie wektora wejściowego do jednej ze skończonej liczby dyskretnych kategorii, nazywamy klasyfikacyjnymi. Natomiast w przypadku, gdy oczekiwanym wynikiem jest jedna lub więcej zmiennych ciągłych, mamy do czynienia z regresją [12].

W niniejszej pracy zastosowano metodykę uczenia nadzorowanego, wykorzystując wybrane algorytmy klasyfikacyjne i regresyjne opisane w dalszej części rozdziału. Podejście to pozwala na zestawienie rzeczywistych wskaźników popularności z prognozami algorytmów, weryfikując przy tym zdolności predykcyjne modeli.

2.2. Regresja Liniowa

W rozumieniu statystycznym, regresja liniowa (ang. *Linear Regression*, LR) dotyczy grupy metod opartych na liniowych kombinacjach zmiennych i paramentów, które dopasowują model do danych. Dopasowana krzywa regresji reprezentuje oszacowaną wartość zmiennej objaśnianej y dla konkretnych wartości jednej lub więcej zmiennych objaśniających x [13].

Ze względu na swoją prostotę obliczeniową i interpretacyjną, regresja liniowa stanowi często pierwszy wybór w analizach, służąc jako model bazowy (ang. *baseline*) do porównywania bardziej złożonych algorytmów [14].

2.2.1. Regresja liniowa prosta

Model regresji liniowej prostej (ang. *Simple Linear Regression*) definiuje zależność między zmienną objaśnianą o jedną zmienną objaśnianą za pomocą funkcji liniowej danej wzorem

$$y = \beta_0 + \beta_1 x + \epsilon \quad (2.1)$$

Parametr β_0 (wyraz wolny) określa przecięcie prostej z osią y , natomiast β_1 określa jej nachylenie (współczynnik kierunkowy). Składowik ϵ jest błędem losowym. Zakłada się, że wartości ϵ_i mają rozkład o zerowej średniej i stałej wariancji, a więc nie są ze sobą skorelowane [13].

2.2.2. Regresja wieloraka

W przypadku, gdy zmienną objaśnianą y opisuje zbiór zmiennych objaśniających $x_1, \dots, x_p$, mówi się o regresji wielorakiej (ang. *Multiple Linear Regression*). Model przyjmuje wówczas postać:

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n + \epsilon \quad i = 1, \dots, n \quad (2.2)$$

Równanie opisuje hiperpłaszczyznę w p -wymiarowej przestrzeni regresorów (zmiennych objaśniających). Współczynniki β_j (dla $j = 1, \dots, n$) nazywane są współczynnikami regresji. Interpretuje się je jako oczekiwaną zmianę wartości zmiennej objaśnianej y w wyniku jednostkowej zmiany zmiennej objaśniającej x_j , przy założeniu, że wartości pozostałych zmiennych objaśniających są stałe.

W zapisie macierzowym, model przyjmuje postać:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad (2.3)$$

gdzie

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}, \quad \boldsymbol{\epsilon} = \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}. \quad (2.4)$$

Zmienna y jest wektorem obserwacji o wymiarach $n \times 1$, $\mathbf{X}$ jest macierzą układu o wymiarach $n \times (p + 1)$, β jest wektorem współczynników regresji o wymiarach $(p + 1) \times 1$, a ϵ to wektor błędów losowych o wymiarach $n \times 1$ [13].

Model ten umożliwia predykcję wartości zmiennej objaśnianej y na podstawie obserwacji zmiennych objaśniających zawartych w macierzy $\mathbf{X}$, przy czym składnik ϵ opisuje losowe odchylenia obserwacji od wartości teoretycznych.

2.3. Regresja Logistyczna

Mimo swojej nazwy, regresja liniowa (ang. *Logistic Regression*, LR) jest z reguły używana w zadaniach klasyfikacyjnych. W przeciwieństwie do regresji liniowej, której wynikiem jest ciągła wartość liczbowa, regresja logistyczna modeluje prawdopodobieństwo przynależności obserwacji do danej klasy [12].

2.3.1. Model binarny

W podstawowym wariacie regresji logistycznej, zmienna celu przyjmuje tylko dwie wartości (0 i 1). Aby przetransformować wynik równania liniowego do przedziału $(0, 1)$ używana jest funkcja logiczna (sigmoidalna). Prawdopodobieństwo sukcesu wyraża się wzorem:

$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}. \quad (2.5)$$

gdzie X oznacza zmienną objaśniającą (cechę wejściową), natomiast β_0 i β_1 to parametry modelu (odpowiednio: wyraz wolny i współczynnik nachylenia).

Aby uniknąć predykcji spoza logicznego zakresu prawdopodobieństwa (poniżej 0 lub powyżej 1), modeluje się tzw. logarytm szans (ang. *log-odds*):

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X. \quad (2.6)$$

Wyrażenie $\frac{p(X)}{1 - p(X)}$, nazywane szansą (ang. *odds*), może przyjmować dowolną wartość z przedziału $(0, \infty)$. Wartości bliskie zeru wskazują na bardzo niskie, a te wartości dążące do nieskończoności – wysokie – prawdopodobieństwo wystąpienia zdarzenia pozytywnego [15].

2.3.2. Model wieloklasowy

W przypadku gdy zmienna objaśniana może przyjąć więcej niż dwa stany, modeluje się prawdopodobieństwo warunkowe $Pr(Y = k|X)$ dla każdej z K klas, przy zachowaniu warunku, że suma prawdopodobieństw dla wszystkich klas musi wynosić 1 [15].

W statystyce prawdopodobieństwa te oblicza się w oparciu o twierdzenie Bayesa, jednak w nowoczesnych implementacjach regresji logistycznej (np. w bibliotece `scikit-learn`) ich estymacja

odbywa się zazwyczaj przy użyciu funkcji *Softmax*, która stanowi uogólnienie funkcji logistycznej dla problemów wielowymiarowych. Dla k -tej klasy prawdopodobieństwo obliczane jest wzorem:

$$P(Y = k|X) = \frac{e^{a_k}}{\sum_{j=1}^K e^{a_j}}, \quad (2.7)$$

gdzie a to wynik funkcji liniowej dla danej klasy. Funkcja ta normalizuje wyniki, sprawiając, że wszystkie prawdopodobieństwa są dodatnie i sumują się do jedności, co pozwala na jednoznaczne wskazanie klasy zwycięskiej [12].

2.4. Drzewa Decyzyjne i Las Losowy

O ile modele liniowe dobrze radzą sobie z interpretacją prostych zależności, ich skuteczność w przypadku problemów nieliniowych bywa ograniczona.

W celu uchwycenia bardziej skomplikowanych relacji między cechami utworu a jego popularnością, w pracy wykorzystano metody oparte na strukturach drzewiastych.

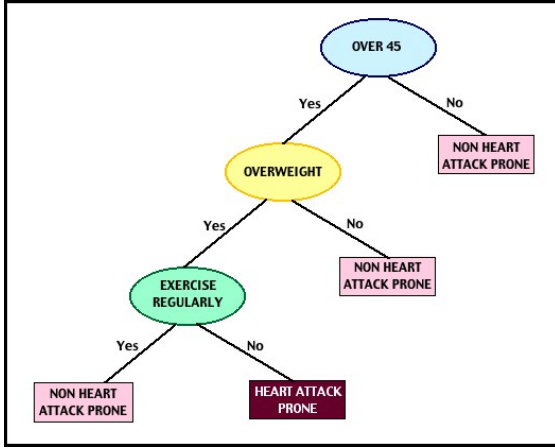
2.4.1. Drzewa Decyzyjne

W informatyce drzewem decyzyjnym (ang. *Decision Tree*) nazywamy strukturę predykcyjną, która rekurencyjnie dzieli dane w przestrzeni, stosując w wydzielonych obszarach proste reguły decyzyjne [16]. Drzewo decyzyjne składa się z korzenia (ang. *root node*), inicjującego proces decyzyjny poprzez podział obserwacji na rozłączne grupy, oraz węzły końcowe, zwane liśćmi (ang. *leaf nodes*), które reprezentują ostateczny wynik predykcji [17].


Do najpopularniejszych algorytmów należą zaproponowane przez Breimana drzewa klasyfikacyjne i regresyjne C&RT (ang. *Classification and Regression Trees*) [18]. Drzew klasyfikacyjnych używa się, gdy zmienna objaśniana przyjmuje jedną ze skończonej liczby kategorii. Drzew regresyjnych używa się natomiast dla zmiennych zależnych przyjmujących wartości ciągłe lub uporządkowane wartości dyskretne [19].

2.4.2. Las Losowy

Las Losowy (ang. *Random Forest*, RF) jest algorytmem należącym do grupy metod uczenia zespołowego (ang. *Ensemble Learning*). Dzięki połączeniu wielu modeli bazowych (w tym wypadku drzew decyzyjnych) w zespół (ang. *ensemble*), możliwym jest uzyskanie wyniku dokładniejszego niż w przypadku pojedynczego estymatora. Algorytm wykorzystuje tzw. podwójną randomizację – losowy dobór próbek treningowych oraz losowy wybór podzbioru cech w każdym węźle. Takie podejście minimalizuje korelację między poszczególnymi drzewami, co skutecznie łagodzi problem nadmiernego dopasowania (ang. *overfitting*) i zwiększa ogólną dokładność modelu [17].



(a) Drzewo klasyfikacyjne określające ryzyko choroby serca na podstawie wieku, wagi oraz aktywności fizycznej. Źródło: University of Minnesota Morris [20].



(b) Drzewo regresyjne szacujące przewidywaną cenę nieruchomości na podstawie danych *Boston Housing*. Źródło: Frontline Solvers [21].

Rys. 2.1. Porównanie struktury drzewa klasyfikacyjnego i regresyjnego.

2.5. Wzmacnianie Gradientowe

Alternatywną grupę metod predykcyjnych stanowią techniki sekwencyjne, w których każdy kolejny model wykorzystuje informacje z poprzednich etapów uczenia. Podobnie jak w przypadku lasu losowego, metody wzmacniania (ang. *boosting*) należą do rodziny algorytmów zespołowych, wykorzystujących drzewa decyzyjne jako estymatory bazowe. W przypadku Lasów Losowych, drzewa buduje się niezależnie od siebie. Boosting natomiast używa metody sekwencyjnej – w każdej iteracji trenowany jest nowy model bazowy, którego celem jest redukcja błędu popełnionego przez dotychczasowy zespół.

W metodzie maszyn wzmacniania gradientowego (ang. *Gradient Boosting Machines*, GBM) dąży się do tego, aby kolejne modele bazowe były maksymalnie skorelowane z ujemnym gradientem funkcji straty całego algorytmu zespołowego [22].

W rozumieniu matematycznym, proces ten jest realizacją algorytmu spadku gradientu (ang. *gradient descent*) w przestrzeni funkcyjnej. W m -tej iteracji algorytm dąży do znalezienia takiej funkcji $h_m(x)$, która przybliży ujemny gradient funkcji straty L . Zgodnie z definicją Friedmana [23], ostateczny model $F(x)$ przyjmuje postać addytywną:

$$F(x) = \sum_{m=0}^M \beta_m h(x; a_m), \quad (2.8)$$

gdzie $h(x; a_m)$ to funkcje bazowe (drzewa), a β_m to współczynniki ekspansji.

W m -tej iteracji algorytm oblicza gradient funkcji straty $g_m(x_i)$ dla każdej obserwacji, zdefiniowany jako:

$$g_m(x_i) = \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)}. \quad (2.9)$$

Wartość $-g_m(x_i)$ wyznacza tzw. pseudo-reszty (kierunek najszybszego spadku), do których dopasowywane jest nowe drzewo $h(x; a_m)$. Następnie model jest aktualizowany według reguły:

$$F_m(x) = F_{m-1}(x) + \nu \cdot \beta_m h(x; a_m), \quad (2.10)$$

gdzie ν (często oznaczane też jako η) to parametr *learning rate*, skalujący wkład współczynnika β_m w celu zapobiegania przeuczeniu.

Rozwinięciem klasycznej metody wzmacniania jest algorytm XGBoost (ang. *eXtreme Gradient Boosting*), uwzględniający w funkcji celu dodatkowy człon regularyzacyjny Ω . W notacji zaproponowanej przez Chena i Guestrina [24], rola nowego estymatora bazowego oznaczana jest jako f_t :

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t), \quad (2.11)$$

gdzie $f_t(x_i)$ odpowiada nowemu drzewu dodawanemu do zespołu, a Ω jest członem karnym.

Użycie regularyzacji zapobiega przeuczaniu się modelu (ang. *overfitting*) i kontroluje złożoność drzewa, nakładając kary za zbyt dużą liczbę liści oraz za przypisywane do nich zbyt wysokie wagi.

2.6. Maszyny Wektorów Nośnych

Użycie maszyn wektorów nośnych (ang. *Support Vector Machines*, SVM) jest popularne w przypadku problemów klasyfikacyjnych. Ich działanie opiera się na separacji obiektów w przestrzeni cech przy użyciu hiperpłaszczyzny, poprzez ustalenie maksymalnego marginesu odległości pomiędzy poszczególnymi klasami [25].


2.6.1. Działanie algorytmu

Algorytm SVM został początkowo zaprojektowany do klasyfikacji binarnej [26]. Dla zadanego zbioru treningowego złożonego z n punktów postaci $(x_1, y_1), \dots, (x_n, y_n)$ znajduje się płaszczyznę o maksymalnym marginesie, dzielącą zbiór na dwie klasy. Współrzędne y_i osiągają wartość 1 lub -1 , przydzielając x_i do poszczególnych klas [27].

Optymalna hiperpłaszczyzna spełnia zależność:

$$\mathbf{w}^T \mathbf{x} + b = 0, \quad (2.12)$$

gdzie $\mathbf{w}$ jest wektorem normalnym do hiperpłaszczyzny, a parametr b (ang. *bias*) określa przesunięcie hiperpłaszczyzny względem początku układu współrzędnych [27].



Rys. 2.2. Schemat działania klasyfikatora SVM. Punkty zakreślone na czarno wyznaczają największy margines pomiędzy dwiema klasami. Źródło: Wikimedia Commons [28].

2.6.2. Problemy nieseparowalne liniowo

W problemach rzeczywistych, dane rzadko są liniowo separowalne. W takich przypadkach stosuje się SVM z marginesem miękkim (ang. *soft-margin*), zaproponowane przez Cortes i Vapnika [27]. Zastosowanie takiego podejścia dopuszcza błędne sklasyfikowanie pewnej liczby punktów, pozwalając na uzyskanie szerszego marginesu separacyjnego.

Optymalizacja takiego problemu polega wówczas na maksymalizacji marginesu, przy jednoczesnej penalizacji punktów leżących po złej stronie granicy marginesu. Należy więc zminimalizować wyrażenie:

$$\frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)), \quad (2.13)$$

gdzie dodatni parametr C stanowi kompromis pomiędzy wielkością marginesu a sumarycznym błędem klasyfikacji. Funkcja $\max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b))$ nazywana jest funkcją straty (ang. *Loss Function*) [12].

2.6.3. Klasyfikacja nieliniowa i problemy wieloklasowe

W przypadku klasyfikacji nieliniowej, stosuje się tzw. *kernel trick* (sztuczkę jądrową), polegającą na mapowaniu danych do wyższego wymiaru przestrzeni euklidesowej, w którym możliwe jest ich liniowe odseparowanie. W nowej przestrzeni iloczyny skalarnie zastępowane są funkcjami jądra (ang. *Kernel Function*) postaci $K(\mathbf{x}_i, \mathbf{x}_j)$. Najczęściej występują jądra wielomianowe, radialne (RBF) oraz sigmoidalne [29]. Z uwagi na nieliniową naturę zależności w danych w danych muzycznych, w niniejszej pracy zdecydowano się na wykorzystanie maszyny wektorów nośnych z jądrem radialnym (RBF).

SVM nadaje się również do modelowania problemów wieloklasowych (ang. *Multiclass SVM*). Do najpopularniejszych strategii tej metody należą „jeden przeciw wszystkim” (ang. *One-vs-Rest*) oraz „jeden przeciw jednemu” (ang. *One-vs-One*), które dekomponują problem złożony na serię problemów

binarnych. Możliwym jest również uwzględnienie całości danych w jednym złożonym zadaniu optymalizacyjnym [26].

2.7. Sztuczne Sieci Neuronowe

Model sztucznych sieci neuronowych (ang. *Artificial Neural Networks*, ANN) oparty jest na biologicznych sieciach neuronowych, stanowiących podstawę działania ludzkiego mózgu. Organ ten posiada zdolność przetwarzania niejasnych, niekompletnych lub zaszumionych informacji, następnie wyciągania z nich trafnych wniosków.

Dzięki tej właściwości, sztuczne sieci neuronowe umożliwiają modelowanie wysoko nieliniowych relacji między cechami wejściowymi (np. metadanymi utworu) a oczekiwanym wynikiem (popularnością), co znajduje szerokie zastosowanie w zadaniach predykcyjnych.

2.7.1. Budowa biologicznego i sztucznego neuronu

Biologiczny neuron zbudowany jest z ciała komórki (somy), dendrytów oraz aksonu. Dendryty odbierają sygnały od innych neuronów, natomiast akson przekazuje przetworzony impuls dalej. Połączenie aksonu jednego z neuronów z dendrytem drugiego nazywane jest synapsą. To właśnie dzięki synapsom zachodzi ciągły proces przesyłania informacji i uczenia się [30].

Model sztucznego neuronu (Rys. 2.3) stanowi analogię do budowy neuronu biologicznego. Rolę synaps pełnią wektory danych wejściowych $(x_1, x_2, \dots, x_n)$. Są one następnie przekazywane do dendrytów, które w modelu matematycznym reprezentowane są poprzez wagi synaptyczne $(w_1, w_2, \dots, w_n)$, określające siłę wyzwolenia.

Ciało komórki realizuje proces wyliczania sumy ważonej sygnałów wejściowych. W praktycznych realizacjach do obliczonej sumy dodawana jest często stała wartość b nazywana biasem. Pozwala ona na przesunięcie funkcji aktywacji, umożliwiając modelowanie bardziej złożonych zależności. Obliczona wartość trafia do aksonu, wewnątrz którego uruchamia się funkcja aktywacji wyzwalająca neuron. To ona decyduje o ostatecznej postaci sygnału wyjściowego y , przekazywanego do zakończenia aksonu.


Jedną z najbardziej powszechnych funkcji aktywacji neuronu jest funkcja sigmoidalna dana wzorem:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (2.14)$$

Często używa się również funkcji schodkowej, funkcji liniowej, prostowanej jednostki liniowej (funkcji ReLU) lub tangensa hiperbolicznego [30].

2.7.2. Budowa sztucznej sieci neuronowej


Architektura typowej sieci neuronowej opiera się na sekwencyjnym ułożeniu warstw. Pierwszą z nich jest warstwa wejściowa (ang. *input layer*), która przyjmuje wektor danych wejściowych i przekazuje go dalej.



Rys. 2.3. Sztuczny neuron wg modelu McCullocha-Pittsa wraz z analogiami do neuronu naturalnego (graf. P. Rogalewski) [31].

Warstwa ukryta (ang. *hidden layer*) znajduje się między wejściem i wyjściem. Jest to zbiór neuronów nieposiadających bezpośredniego połączenia z otoczeniem zewnętrznym. Sieć może składać się z wielu warstw ukrytych – nazywa się ją wtedy głęboką siecią uczenia (ang. *Deep Neural Network*, DNN).

Ostatni element stanowi warstwa wyjściowa (ang. *output layer*). Składa się ona zazwyczaj z jednego neuronu (w przypadku regresji lub klasyfikacji binarnej) lub wielu neuronów, w zależności od złożoności badanego problemu.



Rys. 2.4. Schemat sieci neuronowej. Opracowanie własne.

Najprostszą siecią neuronową jest perceptron (ang. *Single Layer Perceptron*), składający się z jednego neuronu o regulowanych wagach i biasach, nieposiadający żadnej warstwy ukrytej [32]. Perceptronem wielowarstwowym (ang. *Multi Layer Perceptron*, MLP) nazywamy strukturę zawierającą co najmniej jedną warstwę ukrytą oraz nieliniową funkcję aktywacji [33]. W przeciwieństwie do prostego perceptronu, MLP może aproksymować dowolną funkcję ciągłą, radząc sobie z problemami nieliniowymi.

2.7.3. Proces uczenia się sieci neuronowej

Celem uczenia się wielowarstwowych sieci neuronowych jest znalezienie takiego zestawu wag poszczególnych połączeń synaptycznych, który zminimalizuje całkowity błąd sieci (średnią różnicę między zadaniem a uzyskanym wektorem wyjściowym) [34]. Funkcję błędu nazywa się również funkcją kosztu (ang. *Cost Function*) [11]).

Proces trenowania sieci opiera się na algorytmie propagacji wstecznej (ang. *Backpropagation*). Uczenie podzielone jest na dwa etapy – fazę propagacji w przód (ang. *forward phase*) oraz fazę propagacji wstecz (ang. *backward phase*) [33]. W kroku w przód dane wejściowe przepuszczane są przez kolejne warstwy sieci, aż do wygenerowania wyniku wyjściowego. Natomiast w fazie propagacji wstecznej iteracyjnie oblicza się gradient funkcji straty (ang. *Loss Function*) i aktualizuje wagi połączeń w kierunku przeciwnym do wektora gradientu [34].

W ramach przeprowadzonych badań zdecydowano się na zastosowanie architektury wielowarstwowego perceptronu (MLP) – klasycznej jednokierunkowej sieci, która przy odpowiednim doborze parametrów pozwala na aproksymację dowolnej funkcji ciągłej. Czyni ją to odpowiednią do przedstawionego problemu predykcji popularności zarówno w problemie klasyfikacyjnym, jak i regresyjnym.

2.8. Ocena skuteczności modeli

Aby zweryfikować jakość zbudowanych modeli oraz porównać ich wyniki, zastosowano zestaw standardowych metryk oceny. Wybór odpowiednich miar zależy od specyfiki problemu (regresja lub klasyfikacja) oraz charakterystyki zbioru danych.

2.8.1. Metryki modeli klasyfikacyjnych

W zadaniach klasyfikacyjnych ocenę modelu opiera się na macierzy pomyłek (ang. *confusion matrix*), zliczając wartości TP (przypadki prawdziwie pozytywne), TN (przypadki prawdziwie negatywne), FP (przypadki fałszywie pozytywne) oraz FN (przypadki fałszywie negatywne) [35].

Poniżej przedstawiono wzory metryk dla klasyfikacji binarnej, jednak znajdują one zastosowanie również w klasyfikacji wieloklasowej (np. poprzez zastosowanie uśredniania).

Dokładność

Dokładność (ang. *Accuracy*) określa stosunek poprawnych predykcji do wszystkich obserwacji:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}. \quad (2.15)$$

W przypadku nie zrównoważonych danych (ang. *imbalanced datasets*), gdzie jedna klasa znacząco dominuje nad pozostałymi, dokładność modelu może być myląca.

Precyzja

Precyzja (ang. *Precision*) określa, jak wiele spośród obserwacji zaklasyfikowanych przez model jako pozytywne, faktycznie należało do tej klasy:

$$Precision = \frac{TP}{TP + FP}. \quad (2.16)$$

Wysoka precyzja jest kluczowa w sytuacjach, gdy koszt fałszywego alarmu (FP) jest wysoki.

Czułość

Czułość (ang. *Recall*) dostarcza informacji o zdolności modelu do wykrywania obiektów klasy pozytywnej. Określa, jaką część wszystkich faktycznie pozytywnych przypadków udało się poprawnie zidentyfikować:

$$Recall = \frac{TP}{TP + FN}. \quad (2.17)$$

Miara F1

Miara F1 (ang. *F1-score*) jest średnią harmoniczną precyzji i czułości. Odzwierciedla równowagę między dwiema miarami, działając dobrze nawet w przypadku zbiorów niezbalansowanych:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}. \quad (2.18)$$

Wysoka wartość F1 świadczy o tym, że model ma zarówno wysoką precyzję, jak i wysoką czułość, stanowiąc użyteczne kryterium oceny modelu.

2.8.2. Metryki modeli regresyjnych

W zadaniach regresji, gdzie celem jest przewidzenie wartości ciągłej, kluczowym jest zmierzenie różnicy między wartościami rzeczywistymi a przewidywanymi przez model. W dalszych wzorach przyjęto oznaczenia: y_i – wartość rzeczywista, $\hat{y}_i$ – wartość przewidywana, $\bar{y}$ – średnia wartość zmiennej w zbiorze, n – liczebność próby [15, 36, 37].

Pierwiastek błędu średniokwadratowego (RMSE)

RMSE (ang. *Root Mean Squared Error*) to jedna z najczęściej stosowanych miar w regresji. Obliczana jest jako pierwiastek kwadratowy ze średniej kwadratów błędów:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (2.19)$$

Ze względu na podnoszenie różnic do kwadratu, metryka ta jest wrażliwa na wartości odstające (ang. *outliers*) – duże błędy są karane znacznie surowiej niż małe. Niższa wartość RMSE oznacza lepsze dopasowanie modelu.

Średni błąd bezwzględny (MAE)

MAE (ang. *Mean Absolute Error*) definiuje się jako średnią z wartości bezwzględnych różnic między wartością rzeczywistą a wartością przewidzianą:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|. \quad (2.20)$$

W przeciwieństwie do RMSE, miara MAE jest bardziej odporna na wartości odstające i traktuje wszystkie odchylenia liniowo. Interpretacja MAE jest intuicyjna – informuje, o ile średnio myli się model w jednostkach zmiennej objaśnianej. Podobnie jak w przypadku RMSE, niższa wartość MAE oznacza lepsze dopasowanie modelu, przy czym wartość 0 wskazuje na dopasowanie idealne (brak różnic między wartościami rzeczywistymi a przewidywanymi).

Średni bezwzględny błąd procentowy (MAPE)

MAPE (ang. *Mean Absolute Percentage Error*) wyraża średnią wielkość błędu predykcji względem wartości rzeczywistych w ujęciu procentowym. Jest to jedna z najpopularniejszych miar w zastosowaniach biznesowych ze względu na łatwość interpretacji, dana wzorem:

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|. \quad (2.21)$$

Zaletą MAPE jest niezależność od skali danych, co pozwala na porównywanie wyników między różnymi zbiorami. Głównym ograniczeniem tej metryki jest jednak niemożność jej zastosowania, gdy wartości rzeczywiste y_i wynoszą zero (problem dzielenia przez zero) lub są bliskie zero (co powoduje nienaturalnie wysokie wartości błędu) [36].

Współczynnik determinacji (R^2)

Współczynnik R^2 (ang. *R-squared*) określa, jaka część wariancji zmiennej objaśnianej została wyjaśniona przez model. Wyraża się wzorem:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}. \quad (2.22)$$

Wartość R^2 mieści się zazwyczaj w przedziale $[0, 1]$. Wynik bliski 1 oznacza doskonałe dopasowanie modelu do danych, natomiast wynik bliski 0 świadczy o braku zdolności predykcyjnej (model przewiduje nie lepiej niż średnia arytmetyczna z danych).

3. Metodyka

Przedstawione w poprzednim rozdziale podstawy teoretyczne stanowią fundament dla praktycznej części projektu. Niniejszy rozdział przedstawia szczegółowy opis procesu badawczego. Omówiono w nim wykorzystane środowisko programistyczne, charakterystykę danych źródłowych, proces ich ekstrakcji i czyszczenia, a także procedurę trenowania i oceny modeli uczenia maszynowego.

3.1. Środowisko programistyczne i wykorzystane narzędzia

Techniczną stronę projektu zrealizowano z wykorzystaniem języka programowania *Python* (wersja 3.11.8), sugerując się szeroką dostępnością bibliotek umożliwiających przetwarzanie dużych wolumenów danych oraz algorytmy uczenia maszynowego. Jako zintegrowane środowisko programistyczne (IDE) wykorzystano edytor *Visual Studio Code* z obsługą interaktywnych notatników *Jupyter Notebook*.

W procesie analizy i modelowania wykorzystano następujące biblioteki i frameworki:

- **pandas** [38] oraz **NumPy** [39] – do manipulacji danymi tabelarycznymi, operacji na macierzach oraz obliczeń numerycznych.
- **h5py** [40] – do obsługi plików w formacie hierarchicznym HDF5, w którym zapisany był oryginalny zbiór *Million Song Dataset*.
- **scikit-learn** [41] – jako podstawową bibliotekę do implementacji algorytmów uczenia maszynowego (modele liniowe, SVM, Random Forest), preprocessingu danych oraz obliczania metryk ewaluacyjnych.
- **XGBoost** [42] – do implementacji zaawansowanych algorytmów wzmacniania gradientowego (eXtreme Gradient Boosting).
- **Matplotlib** [43] oraz **seaborn** [44] – do wizualizacji danych oraz generowania wykresów, zarówno na etapie eksploracyjnej analizy danych, jak i podczas prezentacji wyników końcowych.

Obliczenia przeprowadzono lokalnie, wykorzystując stację roboczą (laptop) wyposażoną w procesor Intel Core i5, 16 GB pamięci RAM oraz system operacyjny Microsoft Windows. Ze względu na znaczną objętość surowych danych, kluczowe etapy ekstrakcji wymagały użycia zewnętrznych nośników pamięci oraz optymalizacji zużycia pamięci operacyjnej (RAM).

3.2. Dane źródłowe

Zgodnie z opisem z Sekcji 1.3, w niniejszej pracy wykorzystano *Million Song Dataset (MSD)* [9] – publiczny zbiór danych zawierający cechy audio oraz metadane miliona piosenek. Zbiór ten poszerzono o podzbiór *Taste Profile Subset (TPS)* [45], zawierający informacje na temat historii odtworzeń ponad 384 000 utworów muzycznych przez ponad 1 000 000 unikalnych użytkowników. Integracja wymienionych źródeł stanowi podstawę do stworzenia zestawu danych umożliwiającego kompleksowe trenowanie modeli uczenia nadzorowanego.

Należy zaznaczyć, iż zestaw ten powstał w roku 2011, w związku z czym zawiera informacje jedynie o utworach wydanych przed tą datą.

3.3. Ekstrakcja danych i wstępna inżynieria cech

Dane pozyskano z oficjalnej strony projektu MSD oraz platformy Hugging Face [46]. Z uwagi na ograniczenia sprzętowe oraz objętość danych, z dostępnych 26 podzbiorów (katalogi A-Z) wykorzystano 11 (katalogi A-K), co pozwoliło na zgromadzenie metadanych ponad 160 000 utworów.

3.3.1. Przetwarzanie wstępne i selekcja atrybutów

Pliki źródłowe HDF5 i przetworzone do formatu tabelarycznego (.csv) przy użyciu biblioteki `h5py` poprzez iteracyjną ekstrakcję wartości z drzewiastej struktury plików. Spośród 46 atrybutów dostępnych w specyfikacji zbioru [47], do dalszej analizy zachowano 15 kluczowych zmiennych:

- **Cechy akustyczne:** `loudness`, `tempo`, `time_signature`, `key`, `mode`, `duration`, `start_of_fade_out`, `end_of_fade_in`.
- **Metadane:** `year`, `artist_hottnesss`, `song_hottnesss`, `artist_name`, `release`, `song_id`, `title`.

Zbiór wzbogacono również o kolumnę `play_count` (liczba odtworzeń) pozyskaną z zestawu TPS.

3.3.2. Agregacja cech wektorowych

MSD zawiera również wielowymiarowe tablice czasowe: `segments_loudness_max`, `segments_timbre` oraz `segments_pitches`, których agregacja pozwoliła na wyznaczenie skalarnych zmiennych statystycznych:

- `loudness_max_std` – odchylenie standardowe maksymalnej głośności,
- `timbre_mean`, `timbre_std` – średnia barwa dźwięku i jej zróżnicowanie,
- `pitch_variety` – miara złożoności melodycznej.

3.3.3. Cechy tekstowe i czasowe

W celu ekstrakcji gatunku muzycznego, wykorzystano tablice `artist_terms` oraz `artist_mbtags`. Przy pomocy metody *One-Hot-Encoding* zakodowano 10 najpopularniejszych tagów (pop, rock, jazz, electronic, hip hop, rap, metal, soul, punk, classical), uzyskując binarne kolumny w formacie `is_[genre]`.

Aby nadać utworom kontekstu czasowego, na podstawie kolumny `year` wyliczono wiek utworu (przyjmując rok 2011 jako wartość referencyjną). Dodatkowo utworzono grupę zmiennych binarnych `is_[decade]`, określających dekadę, z której pochodzi utwór (lata 80., 90., itp.).

3.4. Eksploracyjna analiza danych (EDA)


3.4.1. Analiza zmiennej objaśnianej

W analizowanym problemie zmienną objaśnianą jest liczba odtworzeń utworu (`play_count`). Jak przedstawiono na Rysunku 3.1, jej rozkład jest prawostronnie skośny i odzwierciedla efekt długiego ogona (ang. *long tail* [48]). W zestawie dominują utwory o niskiej popularności, podczas gdy osiągające setki tysięcy odtworzeń „hity” stanowią nieliczną grupę.

Mając na uwagę charakterystykę zmiennej `play_count`, zdecydowano się na osobne strategie modelowania dla problemów klasyfikacyjnych i regresyjnych:

- w zadaniach klasyfikacyjnych, aby zniwelować wpływ wartości odstających, zmienną zdyskretyzowano do czterech klas popularności:
 - **Obscure:** < 50 odtworzeń,
 - **Underground:** $50 - 500$ odtworzeń,
 - **Popular:** $500 - 5000$ odtworzeń,
 - **Viral:** > 5000 odtworzeń;
- w zadaniach regresyjnych zastosowano transformację logarytmiczną ($\log(1 + x)$), która pozwoliła na zbliżenie rozkładu zmiennej do rozkładu normalnego.

W celu zobrazowania redukcji skośności, na Rysunku 3.1 zestawiono rozkład zmiennej objaśnianej w postaci surowej oraz po transformacji logarytmicznej.




Rys. 3.1. Porównanie rozkładu zmiennej `play_count`: dane surowe (z lewej) oraz po zlogarytmowaniu (z prawej).

3.4.2. Rozkłady zmiennych objaśniających

W celu pełnego zrozumienia charakterystyki zbioru danych, przeanalizowano rozkłady pozostałych zmiennych, opisujących metadane utworu, jego strukturę muzyczną oraz właściwości akustyczne.

Dekada i gatunek muzyczny

Analiza gatunku muzycznego i dekady (Rysunek 3.2) wykazała, że w zestawie danych przeważają utwory rockowe, popowe i muzyka elektroniczna, a najmniej liczną grupę stanowią kompozycje klasyczne. Muzyka wydana w latach 1990–2010 wyraźnie dominuje, podczas gdy utwory wydane przed rokiem 1950 stanowią margines zbioru. Jest to naturalne zjawisko, biorąc pod uwagę źródło danych (serwisy cyfrowe) oraz wszechobecną dominację muzyki współczesnej.



Rys. 3.2. Rozkład liczby utworów w podziale na gatunki oraz dekady muzyczne.


Rozpoznawalność i popularność artysty

Mimo intuicyjnego podobieństwa metryk opisujących artystę, analiza porównawcza (Rysunek 3.3) ujawniła znaczące różnice w rozkładach zmiennych `artist_hottness` oraz

artist_familiarity. Rozpoznawalność artysty jest zjawiskiem bardziej rozproszonym, przesuniętym w stronę wartości wyższych (dominanta w przedziale 0.6–0.7) z lekką lewostronną skośnością.

Z kolei rozkład popularności jest węższy i skoncentrowany wokół średniej wynoszącej około 0.4, z zauważalnym peakiem przy wartości 0. Sugeruje to, że większość artystów mieści się w podobnym, „trendującym” przedziale, z wyraźnym udziałem artystów niepopularnych lub zapomnianych.


Powyższe zależności wskazują, że w zbiorze przeważają artyści o umiarkowanej popularności i rozpoznawalności, przy niewielkim udziale globalnych gwiazd.



Rys. 3.3. Rozkład wskaźników popularności artysty: *hottness* oraz *familiarity*.

Tonacja, tryb, metrum

W przypadku atrybutów kategoriycznych (Rysunek 3.4) widoczna jest wyraźna dominacja metrum 4/4 (*time_signature*=4). Dodatkowo zauważono przewagę tonacji durowych (*mode*=1) nad molowymi (*mode*=0), co jest również widoczne w rozkładzie zmiennej *key*.




Rys. 3.4. Liczebność klas dla zmiennych kategoriycznych: tonacji, trybu oraz metrum.

Tempo i głośność

Analiza podstawowych cech muzycznych (Rysunek 3.5) dostarcza istotnych informacji o strukturze utworów. Zmienna (`tempo`) ma rozkład wielomodalny, z wyraźnie widocznymi dwiema dominantami: mniejszą w przedziale 90–100 BPM oraz główną w okolicach 120–130 BPM, co jest w muzyce zjawiskiem typowym, wynikającym z występowania harmonik tempa (ang. *beat harmonics*), będących wielokrotnością tempa podstawowego [49]).


Rozkład zmiennej (`loudness`) jest przesunięty w stronę wartości ujemnych (zgodnie ze skalą dB). Największa koncentracja jest widoczna w przedziale od -15 B do -5 dB, co potwierdza zjawisko spłaszczania dynamiki utworu (ang. *overcompression*) w muzyce współczesnej [50].



Rys. 3.5. Rozkłady zmiennych ciągłych: tempa oraz głośności (`loudness`).

Cechy sygnałowe


Jak opisano w Sekcji 3.3.2, zbiór danych został wzbogacony o uśrednione wektory opisujące barwę (`timbre_mean`, `timbre_std`), zróżnicowanie wysokości dźwięku (`pitch_variety`) oraz zmienność maksymalnej głośności (`loudness_max_std`) utworu. Wizualizacja rozkładów tych cech (Rysunek 3.6) wskazuje, że o ile rozkłady zmiennych `timbre_mean`, `pitch_variety` oraz (`loudness_max_std`) są relatywnie symetryczne i skupione wokół średniej, zmienna `timbre_std` wykazuje silną prawostronną skośność.




Rys. 3.6. Rozkłady cech sygnałowych: barwy, tonalności oraz dynamiki.

Atrybuty czasowe

Zmienne czasowe wymagały szczególnej uwagi. Pierwotne rozkłady długości trwania utworów (duration) oraz momentów startu i końca efektów *fade* (start_of_fade_out, end_of_fade_in) charakteryzowały się silną prawostronną skośnością (Rysunek 3.7a).



(a) Rozkłady zmiennych czasowych przed transformacją.




(b) Rozkłady po transformacji logarytmicznej.

Rys. 3.7. Wpływ logarytmizacji na rozkład cech czasowych.

Szczegółowa weryfikacja potwierdziła występowanie utworów trwających nawet ponad 40 minut (2400–3000 sekund), dlatego zdecydowano się na zachowanie wartości odstających jako rzeczywistych danych. Zastosowano transformację logarytmiczną (Rysunek 3.7b), która pozwoliła na skuteczne znormalizowanie zmiennych duration oraz start_of_fade_out. W przypadku zmiennej end_of_fade_in nie odnotowano poprawy symetrii rozkładu.

Ze względu na specyfikę zmiennej `end_of_fade_in`, zdecydowano się wyodrębnić osobny atrybut binarny `has_fade_in`, określający, czy w danym utworze występuje efekt zgłaśniania. Analiza tego atrybutu wykazała ponad dwukrotną przewagę utworów posiadających ten efekt.

Aby dopełnić obrazu przejść dynamicznych, wyodrębniono również zmienną `has_fade_out`, która wykazała dziesięciokrotną przewagę utworów z końcowym wyciszeniem. Porównanie występowania tych efektów przedstawiono na Rysunku 3.8.




Rys. 3.8. Rozkład występowania efektów *fade-in* oraz *fade-out*.

Rok wydania utworu

Z uwagi na występowanie wysokiego odsetka wartości pustych, analiza rozkładu zmiennej `year` została omówiona w Sekcji 3.5.1.

3.4.3. Analiza korelacji i redukcja nadmiarowości

Aby zweryfikować współzależności między zmiennymi oraz ocenić skuteczność selekcji cech, wygenerowano macierze korelacji Pearsona dla zbioru przed oraz po procesie redukcji (Rysunek 3.9).



(a) Macierz korelacji przed selekcją cech.

(b) Macierz korelacji po usunięciu skorelowanych zmiennych.

Rys. 3.9. Zestawienie korelacji zmiennych przed i po procesie inżynierii cech. Powiększone wizualizacje znajdują się w Dodatku A.

Analiza macierzy korelacji ujawniła całkowitą zależność liniową ($r = -1.0$) pomiędzy zmiennymi `year` i `song_age`. Jest to rezultat oczekiwany, gdyż wiek utworu stanowi liniową transformację roku wydania. Zmienne te niosą więc matematycznie tożsamą informację (zjawisko redundancji). Silne powiązania odnotowano również pomiędzy rokiem wydania a binarnymi flagami dekad (`is_[decade]`), gdzie współczynniki korelacji sięgały -0.8 . Mimo że algorytmy drzewiaste (Random Forest, XGBoost) dobrze radzą sobie z korelacją zmiennych, pozostałe modele są wrażliwe na współliniowość. W związku z powyższym, podjęto decyzję o pozostawieniu w zbiorze wyłącznie zmiennej `year`, którą poddano późniejszej standaryzacji. Zmienną `song_age` oraz flagi dekad usunięto w ramach selekcji cech.


Kolejną istotną informacją była niemal całkowita zależność liniowa między zmiennymi `duration_log` oraz `start_of_fade_out_log`. Wskazuje to na fakt, że w większości analizowanych utworów moment rozpoczęcia wyciszenia (ang. *fade-out*) pokrywa się z końcem ścieżki dźwiękowej. Biorąc pod uwagę, że długość trwania utworu jest informacją bardziej intuicyjną i istotną dla modelu, zdecydowano się na pozostawienie w zbiorze jedynie kolumny `duration_log`. Informacja o występowaniu wyciszenia została zachowana w binarnej zmiennej `has_fade_out`.

Zauważalną korelację ($r = 0.7$) odnotowano również dla pary atrybutów opisujących wykonawcę: `artist_familiarity` oraz `artist_hottnesss`, informujących o rozpoznawalności i popularności artysty. Mimo statystycznego powiązania, zmienne te dostarczają odmiennych informacji. Atrybut *familiarity* odzwierciedla długofalową rozpoznawalność artysty (jego ugruntowaną pozycję), natomiast *hottnesss* opisuje bieżącą popularność (aktualny trend). Uznano, iż rozróżnienie tych informacji może być kluczowe dla skuteczności predykcji, gdyż artysta wysoce rozpoznawalny nie musi być obecnie popularny i odwrotnie. Z tego względu zdecydowano się na pozostawienie obu zmiennych, akceptując ich umiarkowaną współliniowość.

3.5. Preprocessing

3.5.1. Obsługa brakujących danych


Analizę kompletności zbioru danych przeprowadzono przy użyciu biblioteki `missingno`, wizualizując rozkład brakujących wartości w poszczególnych kolumnach.



Rys. 3.10. Rozkład braków danych w poszczególnych kolumnach.

W przypadku większości atrybutów braki danych miały charakter marginalny (poniżej 0.004% wszystkich obserwacji). Ze względu na ich znikomy wpływ na liczebność próby zdecydowano się na usunięcie niekompletnych rekordów.

W przypadku kolumny `year` procent wartości brakujących wyniósł prawie 31.5%. Sprawdzone rozkład zmiennej i podjęto próbę imputacji braków przy użyciu mediany. Niestety, z uwagi na skośność rozkładu i relatywnie duży odsetek braków, zabieg ten doprowadził do sztucznego zniekształcenia rozkładu i powstania nienaturalnej dominanty w jednym roku.



Rys. 3.11. Wpływ imputacji medianą na rozkład zmiennej `year`.

Biorąc pod uwagę ryzyko zaburzenia danych oraz fakt, że pierwotny zbiór był bardzo obszerny (ponad 160 000 utworów), podjęto decyzję o odrzuceniu metody imputacji i całkowitym usunięciu wybrakowanych rekordów. Po tej operacji ostateczna liczebność zbioru danych wyniosła około 111 000 obserwacji, co stanowi wystarczającą bazę do trenowania modeli uczenia maszynowego.

3.5.2. One-Hot-Encoding

Atrybuty katagoryczne `key` (tonacja) oraz `time_signature` (metrum) poddano transformacji na wektory binarne przy użyciu metody *One-Hot Encoding*.

Dla zwiększenia czytelności analizy numeryczne oznaczenia (0-11) zmiennej `key` zostały zmapowane na odpowiadające im nazwy tonacji w notacji muzycznej (ang. Pitch Class Notation). Schemat mapowania przedstawiono w tabeli 3.1.

Tabela 3.1. Mapowanie wartości numerycznych na nazwy tonacji.

Kod	Tonacja	Kod	Tonacja	Kod	Tonacja
0	C	6	F#	4	E
1	C#	7	G	10	A#
2	D	8	G#	5	F
3	D#	9	A	11	B

3.5.3. Podział danych na zbiór treningowy i testowy

Końcowy zbiór danych został podzielony na dwie rozłączne części: zbiór treningowy (80%), służący do uczenia modeli, oraz zbiór testowy (20%), wykorzystywany do weryfikacji ich dokładności.

W procesie podziału zastosowano stałe ziarno losowe (`seed=416457`), co umożliwia pełne odtworzenie eksperymentów. Liczebności zbiorów po podziale przedstawiono w Tabeli 3.2.

Tabela 3.2. Liczebność zbiorów danych po podziale.

Zbiór	Liczba obserwacji	Udział procentowy
Treningowy	89 072	80%
Testowy	22 269	20%
Suma	111 341	100%

3.6. Trenowanie modeli

Proces trenowania modeli przeprowadzono dwutorowo, definiując problem predykcji popularności zarówno jako zadanie klasyfikacyjne (przypisanie do przedziału popularności), jak i regresyjne (szacowanie dokładnej liczby odtworzeń).

W ramach każdego z podejść przetestowano zestaw pięciu zróżnicowanych algorytmów, reprezentujących różne rodziny modeli:

- modele liniowe (Regresja Logistyczna / Liniowa),
- modele oparte na drzewach decyzyjnych (Random Forest),
- modele odległościowe (SVM),
- modele boostingowe (XGBoost),
- sieci neuronowe (MLP).

3.6.1. Problem klasyfikacyjny

Celem podejścia klasyfikacyjnego było przypisanie utworowi jednej z czterech etykiet: *Obscure*, *Underground*, *Popular* lub *Viral* (szczegółową charakterystykę klas opisano w Sekcji 3.4.1).

Jako punkt odniesienia (ang. *baseline*) wykorzystano model Regresji Logistycznej. Następnie badanie rozszerzono o bardziej złożone klasyfikatory: Las Losowy (*Random Forest Classifier*), Maszynę Wektorów Nośnych (SVM), algorytm XGBoost oraz sieć neuronową MLP. Z uwagi na niezbalansowany charakter zbioru danych, koniecznym było użycie parametru `class_weight='balanced'`.

3.6.2. Problem regresyjny

W zadaniu regresyjnym jako zmiennej objaśnianej użyto zlogarytmowanej liczby odtworzeń (`play_count_log`). Zastosowanie transformacji logarytmicznej (uzasadnionej w Sekcji 3.4.1) było konieczne ze względu na silną skośność rozkładu zmiennej celu oraz wymogi modeli liniowych.

Analogicznie do problemu klasyfikacji, jako model bazowy przyjęto Regresję Liniową. Zestawienie uzupełniono o regresyjne odpowiedniki pozostałych algorytmów: Random Forest Regressor, Support Vector Regressor, XGBoost Regressor oraz MLP Regressor.

Dokładną charakterystykę wymienionych modeli klasyfikacyjnych i regresyjnych można znaleźć w Rozdziale 2, natomiast analiza ich skuteczności na badanym zbiorze danych stanowi przedmiot Rozdziału 4.

3.7. Ocena skuteczności modeli

Weryfikację jakości modeli klasyfikacyjnych oparto na czterech podstawowych miarach: dokładności (ang. *Accuracy*), precyzji (ang. *Precision*), czułości (ang. *Recall*) oraz indeksie F1.

W przypadku modeli regresyjnych błąd predykcji oszacowano przy użyciu: pierwiastka błędu średniokwadratowego (RMSE), średniego błędu bezwzględnego (MAE), średniego bezwzględnego błędu procentowego (MAPE) oraz współczynnika determinacji (R^2).

Szczegółowe definicje matematyczne oraz interpretację powyższych wskaźników przedstawiono w Sekcji 2.8. Wyniki eksperymentów, uzyskane w oparciu o zdefiniowane metryki, zostały szczegółowo omówione w Rozdziale 4.

4. Wyniki badań

Zakończenie etapu przetwarzania danych i trenowania modeli pozwala na podsumowanie eksperymentalnej części projektu. Niniejszy rozdział poświęcono analizie wyników uzyskanych w zadaniach klasyfikacji i regresji. Przedstawiono skuteczność modeli bazowych, metod zespołowych oraz efekty optymalizacji. Przedstawiono również syntetyczne zestawienie metryk ewaluacyjnych wszystkich badanych algorytmów.

4.1. Wyniki problemu klasyfikacyjnego

W Tabeli 4.1 zestawiono skuteczność poszczególnych modeli klasyfikacyjnych, przyjmując regresję logistyczną jako punkt odniesienia.

Najlepszą efektywność odnotowano dla modelu Random Forest, który osiągnął najwyższe wyniki we wszystkich analizowanych metrykach. Uzyskał dokładność (*Accuracy*) na poziomie 0.6122 oraz miarę F1-Score równą 0.5782, znacząco przewyższając model bazowy.


Równie wysoką skuteczność wykazały również modele XGBoost oraz MLP. Warto natomiast zauważyć, że model odległościowy (SVM) poradził sobie równie słabo, jak bazowy model liniowy. Sugeruje to, że badany problem charakteryzuje się silną nieliniowością, co utrudnia jego interpretację przez proste metody geometryczne.

Tabela 4.1. Wyniki modeli klasyfikacyjnych. Kolorem zaznaczono najlepszy model.

Model	Accuracy	Precision	Recall	F1-Score
Logistic Regression (baseline)	0.4979	0.5514	0.4979	0.5167
Random Forest	0.6122	0.5869	0.6122	0.5782
Support Vector Machine	0.5248	0.5586	0.5248	0.5357
XGBoost	0.6047	0.5760	0.6047	0.5776
MLP	0.5983	0.5675	0.5983	0.5652

W celu głębszej analizy błędów popełnianych przez najlepszy model (RF) wygenerowano macierz pomyłek (Rysunek 4.1). Jej analiza pokazuje, że model w większości przypadków poprawnie klasyfikuje najliczniejszą klasę (*Obscure*), jednak ma duże problemy z rozpoznawaniem hitów (klasa *Viral*).

W przypadku klas pośrednich (*Underground*, *Popular*) model częściej się myli, niż wskazuje poprawną odpowiedź.



Rys. 4.1. Macierz pomyłek dla modelu Random Forest.

4.2. Wyniki problemu regresyjnego

Modelem bazowym w problemie regresyjnym była regresja liniowa. Analogicznie do problemu klasyfikacyjnego, najwyższą zdolność predykcyjną wykazał algorytm Random Forest. Osiągnął on najniższe wartości błędów dla zlogarytmowanej zmiennej celu ($RMSE = 1.2539$, $MAE = 1.5904$, $MAPE = 54.2224$) oraz najwyższy współczynnik R^2 wynoszący 0.3245.


Drugi najlepszy wynik ponownie odnotowano dla algorytmu XGBoost. Warto zauważyć, że w przypadku zadania regresyjnego wszystkie testowane modele – w tym SVM – osiągnęły wyraźną poprawę wyników w odniesieniu do modelu bazowego.

Nawet dla najlepszego modelu zauważono relatywnie niski procent wyjaśnienia danych (wartości R^2) oraz wysoki błąd procentowy (MAPE). Wskazuje to na dużą złożoność problemu, którego nie udało się wyjaśnić żadną z użytych metod.

Tabela 4.2. Wyniki modeli regresyjnych. Kolorem zaznaczono najlepszy model.

Model	RMSE	MAE	MAPE	R ²
Linear Regression (baseline)	1.7053	1.3604	58.5167	0.2234
Random Forest	1.5904	1.2539	54.2224	0.3245
Support Vector Machine	1.6786	1.3211	55.3306	0.2475
XGBoost	1.6458	1.3041	56.0503	0.2766
MLP	1.6756	1.3276	56.1585	0.2502

Dla najlepszego modelu (RF) sporządzono wykres rozrzutu (Rysunek 4.2), zestawiający wartości rzeczywiste z przewidywanymi przez model. Rozproszenie punktów względem przerywanej linii referencyjnej (wizualizacja idealnej predykcji) pokazuje, że model ma tendencję do zawyżania popularności piosenek o niskiej liczbie odtworzeń oraz nie jest w stanie przewidzieć hitów, spłaszczając predykcje do rzędu 10 000 (przy maksimum wynoszącym 100 000). Rozkład błędów jest zbliżony do rozkładu normalnego, jednak jego szeroki zakres potwierdza niepewność predykcji.

**Rys. 4.2.** Wykres predykcji względem wartości rzeczywistych dla modelu RF.

4.3. Zastosowanie metod zespołowych

Ze względu na zbliżone wyniki uzyskane przez poszczególne modele podstawowe, niezależnie od stopnia ich złożoności, zdecydowano się na eksperyment z użyciem metod zespołowych (ang. *ensemble methods*).

Wykorzystano metodę *VotingClassifier*, która wyznacza klasę wynikową na podstawie największej liczby głosów oddanych przez poszczególne modele.. Użyto głosowania miękkiego (ang. *soft voting*), w którym średnie prawdopodobieństwa klas określają, która z nich będzie ostateczną prognozą.

W pierwszym podejściu skonstruowano zespół hybrydowy, składający się z modelu liniowego (regresji logistycznej dla klasyfikacji i regresji liniowej dla regresji) oraz dwóch algorytmów, które osiągnęły najlepsze wyniki w fazie testów jednostkowych – Random Forest oraz XGBoost (szczegółowe wyniki modeli bazowych znajdują się w Tabelach 4.1 oraz 4.2).

Z uwagi na brak istotnej poprawy wyników przetestowano alternatywny zespół, ograniczony jedynie do modeli opartych na drzewach decyzyjnych. Eliminacja modeli liniowych nieznacznie poprawiła wyniki modelu zespołowego. Wyniki obu eksperymentów przedstawiono w Tabelach 4.3 oraz 4.9.

Tabela 4.3. Porównanie wyników najlepszego modelu klasyfikacyjnego z wynikami metod zespołowych. Kolorem zaznaczono najlepsze wyniki w danej kategorii.

Model	Accuracy	Precision	Recall	F1-Score
Random Forest	0.6122	0.5869	0.6122	0.5782
Ensemble (LR+RF+XBG)	0.6116	0.5859	0.6116	0.5891
Ensemble (RF+XBG)	0.6125	0.5852	0.6125	0.5819

W zadaniu klasyfikacyjnym użycie metod zespołowych przyniosło nieznaczną poprawę wybranych metryk. Zespół uwzględniający regresję logistyczną (LR+RF+XGB) osiągnął najwyższy wynik miary F1, co sugeruje lepszy balans pomiędzy współczynnikami *Precision* i *Recall*. Zespół oparty jedynie na drzewach decyzyjnych (RF+XGB) osiągnął z kolei najlepszy wskaźnik *Accuracy*.

Tabela 4.4. Porównanie wyników najlepszego modelu regresyjnego z wynikami metod zespołowych. Kolorem zaznaczono najlepszy model.

Model	RMSE	MAE	MAPE	R ²
Random Forest	1.5904	1.2539	54.2224	0.3245
Ensemble (LR+RF+XBG)	1.6306	1.2936	55.9098	0.2899
Ensemble (RF+XBG)	1.6119	1.2745	55.0453	0.3061

W przypadku zadania regresyjnego żadna z metod zespołowych nie osiągnęła wyników lepszych niż najlepszy model podstawowy (Random Forest). Dodanie kolejnych estymatorów nie wpłynęło pozytywnie na redukcję błędów ani wysokość wskaźnika R^2 .

4.4. Analiza przeuczenia modeli

Zbadano również zdolność generalizacji modeli podstawowych. Przeprowadzono analizę porównawczą wyników modelowania na zbiorach testowym i treningowym, sprawdzając stopień przeuczenia

modeli (ang. *Overfitting*). To podejście pozwoliło na wytypowanie modeli do późniejszej optymalizacji hiperparametrów opisanej w Sekcji 4.5. Szczegółowe wyniki testów przedstawiono w Tabelach 4.5 oraz 4.6.

Odnotowano silną tendencję do przeuczenia modelu Random Forest, niezależnie od rodzaju rozwiązywanego problemu. W zadaniu klasyfikacyjnym (Tabela 4.5) model ten osiągnął bezbłędną skuteczność na zbiorze uczącym (1.0), podczas gdy na zbiorze testowym wynik spadł do poziomu 0.61. Analogiczną zależność odnotowano w zadaniu regresyjnym (Tabela 4.6), gdzie różnica współczynnika R^2 między zbiorem treningowym a testowym wyniosła ponad 0.35.

W przypadku modelu XGBoost odnotowane różnice były znacznie mniejsze, co świadczy o jego lepszej odporności na przeuczenie. Mimo to, ze względu na obiecujące wyniki bazowe w obu zadaniach, zdecydowano się na przeprowadzenie strojenia hiperparametrów (ang. *hyperparameter tuning*) zarówno dla modelu Random Forest (w celu redukcji overfittingu), jak i XGBoost (w celu maksymalizacji wyników).

Tabela 4.5. Porównanie wskaźnika *Accuracy* na zbiorze treningowym i testowym dla modeli klasyfikacyjnych. Kolorem zaznaczono modele poddane dalszej optymalizacji.

Model	Train Acc	Test Acc	Różnica
Logistic Regression	0.4960	0.4979	-0.0019
Random Forest	1.0000	0.6122	0.3878
SVM	0.5965	0.5248	0.0717
XGBoost	0.6986	0.6047	0.0939
MLP	0.5996	0.5983	0.0013

Tabela 4.6. Porównanie współczynnika R^2 na zbiorze treningowym i testowym dla modeli regresyjnych. Kolorem zaznaczono modele poddane dalszej optymalizacji.

Model	Train R^2	Test R^2	Różnica
Linear Regression	0.2214	0.2234	-0.0021
Random Forest	0.6748	0.3245	0.3503
SVM	0.3378	0.2475	0.0902
XGBoost	0.3341	0.2766	0.0574
MLP	0.2732	0.2502	0.0230

4.5. Strojenie hiperparametrów

W procesie optymalizacji wykorzystano metodę *GridSearchCV* – przeszukiwanie siatki z walidacją krzyżową. Technika ta polega na sprawdzeniu wszystkich możliwych kombinacji w zadanej przestrzeni

parametrów, w celu znalezienia zestawu zapewniającego najlepszą skuteczność modelu, mierzoną na podstawie wyniku walidacji krzyżowej.

Uzyskane w toku eksperymentów optymalne konfiguracje hiperparametrów dla poszczególnych modeli zestawiono w Tabeli 4.7.

Tabela 4.7. Zestawienie hiperparametrów uzyskanych metodą *Grid Search*.

Zadanie	Model	Najlepsze parametry
Klasyfikacja	Random Forest	max_depth=16, n_estimators=200, min_samples_leaf=5, max_features='sqrt'
	XGBoost	max_depth=8, n_estimators=500, learning_rate=0.01, subsample=0.8
Regresja	Random Forest	max_depth=20, n_estimators=300, min_samples_leaf=4, max_features=0.5
	XGBoost	max_depth=7, n_estimators=300, learning_rate=0.05, colsample_bytree=0.7

4.5.1. Wyniki optymalizacji

Modele klasyfikacyjne

Wyniki uzyskane przez modele z dobranymi hiperparametrami zestawiono w Tabeli 4.8. W porównaniu do wyników przed tuningiem, model Random Forest poprawił balans między precyzją a czułością (wyższy wskaźnik $F1$), jednak jego precyzja spadła. Wyniki dla modelu XGBoost w większości się poprawiły, jednak nie osiągnęły wartości wyższych niż RF.

Tabela 4.8. Wyniki strojenia hiperparametrów dla modeli klasyfikacyjnych. Kolorem zaznaczono najlepsze wyniki w danej kategorii.

Model	Accuracy	Precision	Recall	F1-Score
Random Forest	0.6122	0.5869	0.6122	0.5782
XGBoost	0.6047	0.5760	0.6047	0.5776
Random Forest (tuned)	0.5821	0.5833	0.5821	0.5799
XGBoost (tuned)	0.6092	0.5814	0.6092	0.5776

Modele regresyjne

W przypadku modeli regresyjnych, tuning hiperparametrów nieznacznie poprawił wyniki modelu XGBoost, jednak w przypadku algorytmu Random Forest nie odnotowano poprawy w przypadku żadnej z wartości.


Tabela 4.9. Wyniki strojenia hiperparametrów dla modeli regresyjnych. Kolorem zaznaczono najlepsze wyniki w danej kategorii.

Model	RMSE	MAE	MAPE	R ²
Random Forest	1.5904	1.2539	54.2224	0.3245
XGBoost	1.6458	1.3041	56.0503	0.2766
Random Forest (tuned)	1.5941	1.2580	54.4274	0.3214
XGBoost (tuned)	1.6355	1.2947	55.6854	0.2857


4.6. Analiza istotności cech

Kluczowym etapem badania była identyfikacja czynników wpływających na popularność utworu. Na Rysunkach 4.3 oraz 4.4 zestawiono ważność cech wyznaczoną przez modele oparte na strukturach drzewiastych (Random Forest, XGBoost) oraz modele liniowe.

Z uwagi na złożoną strukturę, algorytmy SVM oraz MLP (tzw. modele typu *black-box*), nie oferują bezpośredniego wglądu w wagi przypisane poszczególnym zmiennym. Z tego powodu nie zostały one uwzględnione w analizie.



Rys. 4.3. Wpływ poszczególnych atrybutów na predykcję modeli klasyfikacyjnych.




Rys. 4.4. Wpływ poszczególnych atrybutów na predykcję modeli regresyjnych.


Aby zwiększyć czytelność wyników i wyznaczyć ogólne trendy, zgrupowano zmienne w następujące kategorie semantyczne:

- *artist_info* – zmienne `artist_familiarity` i `artist_hottnesss`, opisujące popularność i rozpoznawalność artysty;
- *music_theory* – cechy harmoniczne i rytmiczne utworu, obejmujące tonację (`key`), tryb (`mode`) oraz metrum (`time_signature`);
- *acoustic_features* – parametry fizyczne dźwięku i jego barwy, takie jak głośność (`loudness`), tempo, `timbre` oraz różnorodność tonów (`pitch_variety`);
- *structural_features* – zmienne opisujące strukturę czasową, w tym czas trwania utworu (`duration`) oraz występowanie efektów *fade-in* i *fade-out*;
- *genre* – zmienne binarne określające przynależność utworu do danego gatunku muzycznego (np. `is_rock`, `is_pop`);
- *year* – rok wydania utworu.

Skumulowany wpływ poszczególnych grup cech na jakość predykcji przedstawiono na Rysunku 4.5.



(a) Istotność cech w klasyfikacji.



(b) Istotność cech w regresji.

Rys. 4.5. Ranking najważniejszych cech wpływających na predykcję modeli

Analiza porównawcza rankingów wykazała, że rozkłady ważności zmiennych różnią się znacząco w zależności od sformułowania problemu badawczego. Cechą wspólną dla obu grup modeli jest wyraźna dominacja metryk opisujących artystę (*artist_info*) – obserwowana zarówno w analizie szczegółowej, jak i skumulowanej.

W przypadku modelu regresji liniowej odnotowano występowanie ujemnych wartości współczynników dla niektórych cech. Wskazuje to na relację odwrotną (negatywną korelację), w której wzrost wartości danego atrybutu wiąże się ze spadkiem przewidywanej popularności. Zjawisko to jest szczególnie widoczne w przypadku zmiennych opisujących gatunek muzyczny (*is_[genre]*) oraz niektórych parametrów barwy dźwięku (*np. timbre_mean, timbre_std*).

W ujęciu zgrupowanym, dla obu podejść odnotowano znikomą istotność roku wydania utworu, mimo jego wysokiej pozycji w rankingu klasyfikacyjnym (Rysunek 4.3). Istotny wpływ na predykcję mają również cechy akustyczne (*acoustic_features*).


Największe rozbieżności dotyczą zmiennych strukturalnych i kontekstowych: w modelach klasyfikacyjnych znaczącą rolę odgrywa informacja o gatunku muzycznym (*genre*), podczas gdy modele regresyjne silniej polegają na parametrach teorii muzyki (*music_theory*).

4.7. Ostateczna ocena jakości predykcji

W ramach ostatecznego podsumowania przeprowadzono analizę porównawczą jakości predykcji dla wszystkich badanych modeli. Pozwoliło to na wizualną ocenę skuteczności różnych rodzin algorytmów.

4.7.1. Porównanie macierzy pomyłek

Na Rysunku 4.6 zestawiono macierze pomyłek dla poszczególnych modeli klasyfikacyjnych. Aby umożliwić bezpośrednie porównanie predykcji, zastosowano ujednoliconą skalę kolorystyczną dla wszystkich wizualizacji.



Rys. 4.6. Zestawienie macierzy pomyłek dla badanych klasyfikatorów.


Analiza macierzy pomyłek ujawniła, że modele o najwyższej ogólnej dokładności, takie jak XGB, MLP, oraz klasyfikatory zespołowe, mają tendencję do faworyzowania klasy większościowej (*Obscure*). Zoptymalizowany model XGB wprowadził poprawnie sklasyfikował najwięcej (10 297) utworów niszowych, jednak odbyło się to kosztem błędnego przypisania do tej kategorii 4 375 utworów z klasy *Underground*. Wskazuje to na to, że mimo zastosowania mechanizmów balansowania klas podczas treningu, modele są mało wrażliwe na mniej liczne klasy.

Co ciekawe, modelem, który poprawnie sklasyfikował najwięcej (164) utworów *Viral*, był bazowy model regresji logistycznej. Jest to znacznie lepszy wynik niż w przypadku modeli osiągających wyższe wskaźniki dokładności. Podstawowy algorytm RF poprawnie sklasyfikował jedynie 16 takich utworów, a XGB – zaledwie 18. Tuning hiperparametrów poprawił jakość predykcji RF – zoptymalizowany model poprawnie sklasyfikował 64 viralowe piosenki. W przypadku modelu XGB, wynik spadł do 10 poprawnych klasyfikacji.

Dodatkowo, wśród wszystkich modeli zauważono trudności z separacją klas pośrednich (*Underground*, *Popular*), myląc je odpowiednio z klasami *Obscure* i *Viral*. sugeruje to, że popularność utworu nie jest cechą kategoriową lecz ciągłą, a sztywno narzucone progi nie znajdują odzwierciedlenia w wyraźnych różnicach muzycznych.

4.7.2. Analiza błędów regresji

W ramach analizy zadania regresyjnego porównano wykresy rozrzutu, zestawiając wartości przewidziane z rzeczywistymi (Rysunek 4.7).



Rys. 4.7. Zestawienie wykresów rozrzutu dla badanych regresorów.


Powyższe zestawienie jednoznacznie uwidacznia ograniczenia badanych modeli w zadaniu predykcji popularności muzyki. Na wszystkich wykresach zaobserwowano podobny efekt – mimo szerokiego zakresu osi odciętych (wartości od 0 do 11 w skali logarytmicznej), chmury punktów skupiają się w przedziale 3–7, tworząc poziomy pas.

Porównanie wartości predykcji z linią idealnego dopasowania ($y = x$), wskazuje, że modele mają silną tendencję do zawyżania popularności utworów niszowych (duże skupisko punktów powyżej prostej) oraz znacznego zaniżania popularności hitów – algorytmy praktycznie nie przewidują wartości wyższych niż 8 (w skali logarytmicznej).


Otrzymane wyniki sugerują, że popularność utworu niełatwo wyjaśnić za pomocą surowych cech muzycznych. Niska korelacja zmiennych skłania modele do „zgadywania” wartości średniej (zjawisko regresji do średniej), co znajduje potwierdzenie zarówno w wizualizacjach, jak i niskich wartościach wskaźnika R^2 .

4.8. Ostateczna ocena metryk modeli

W celu ostatecznego podsumowania przeprowadzonych eksperymentów sporządzono zbiorcze zestawienie metryk skuteczności modeli, uwzględniające wyniki uzyskane po tuningu hiperparametrów oraz rezultaty metod zespołowych. Rysunki 4.8 oraz 4.9 prezentują kompletny ranking algorytmów dla obu sformułowanych problemów badawczych: pierwszy z nich przedstawia skuteczność modeli klasyfikacyjnych, natomiast drugi odnosi się do modeli regresyjnych.



Rys. 4.8. Porównanie metryk *Accuracy*, *Precision*, *Recall*, *F1* dla przetestowanych modeli klasyfikacyjnego.



Rys. 4.9. Porównanie metryk RMSE, MAE, MAPE, R^2 dla przetestowanych modeli regresyjnych.

5. Dyskusja

Realizacja omawianych badań wiązała się z szeregiem wyzwań natury technicznej i merytorycznej. Ograniczenia licencyjne platformy Spotify wymusiły wykorzystanie alternatywnego, historycznego zbioru danych, którego jakość stanowiła istotne wyzwanie analityczne.

Mimo że uzyskane wyniki modelowania wskazują na umiarkowaną skuteczność predykcji opartej wyłącznie na cechach akustycznych, trafnie odzwierciedlają specyfikę branży muzycznej. Sugerują one, że szacowanie potencjału komercyjnego wymaga obecnie zastosowania bardziej zaawansowanych metod, uwzględniających nie tylko sam dźwięk, ale przede wszystkim współczesne mechanizmy dystrybucji muzyki.

5.1. Wyzwania związane z pozyskiwaniem i jakością danych

5.1.1. Ograniczenia platformy Spotify

Jak wspomniano w Sekcji 1.2, kluczowym problemem napotkanym w początkowym etapie projektu okazała się akwizycja danych. Ze względu na restrykcyjne zmiany w polityce licencyjnej serwisu Spotify, pozyskanie współczesnych, jakościowych danych poprzez oficjalne API stało się niemożliwe. Unieвозможиło to odtworzenie metodologii stosowanych w dotychczasowych badaniach (1.1) i wymusiło znalezienie alternatywnych źródeł.

5.1.2. Problematyka zbioru *Million Song Dataset*

Wykorzystanie zbioru *Million Song Dataset* wiązało się z szeregiem problemów technicznych i merytorycznych. Dostępność danych była ograniczona (m.in. wycofanie wsparcia dla publicznych obrazów (snapshots) na platformie AWS, wbrew oficjalnej dokumentacji). Duża objętość zbioru okazała się również problematyczna w kwestii ograniczeń sprzętowych. Dodatkowo, mimo dużego wolumenu, wiele zawartych w zbiorze atrybutów okazało się nieprzydatnych w kontekście zdefiniowanego problemu badawczego.

Istotnym ograniczeniem był również wiek zbioru. Pochodzące z 2011 roku dane nie odzwierciedlają obecnej dynamiki rynku muzycznego. Z uwagi na diametralną zmianę funkcjonowania branży muzycznej (przejście z modelu radiowo- płytowego na streamingowy), wnioskowanie na podstawie archiwalnych danych nie znajduje odzwierciedlenia w obecnym świecie.

5.2. Niezbalansowanie klas a specyfika rynku

Wykorzystany zbiór danych charakteryzował się wyraźnym niezbalansowaniem klas, co jest jednak naturalnym zjawiskiem rynkowym. Przy ogromnym wolumenie produkowanej muzyki zaledwie niewielki odsetek osiąga status międzynarodowych hitów [48].

Choć z perspektywy uczenia maszynowego użycie takich danych znacznie utrudnia proces predykcji, sztuczne balansowanie zbioru mogłoby zaburzyć postrzeganie rzeczywistości i wyuczyć modele nieprzystosowane do rzeczywistego obrazu branży.

5.3. Interpretacja wyników modelowania

Mimo przeprowadzenia badania dwutorowo oraz zastosowania zróżnicowanych podejść – od prostych modeli bazowych po tuning hiperparametrów i metody zespołowe – nie udało się uzyskać zadowalających wyników. Nawet najlepsze modele oparte na drzewach decyzyjnych nie poradziły sobie z problemem, jedynie nieznacznie przewyższyły skuteczność prostych algorytmów regresyjnych.

Prowadzi to do wniosku, że surowe cechy audio nie są wystarczającym predyktorem popularności utworu. Parametry takie jak głośność, tempo czy metrum pełnią jedynie rolę drugoplanową, gdy sukces komercyjny utworu determinowany jest przez inne specyficzne dla branży czynniki.

5.4. Dominacja artysty

Przeprowadzona analiza istotności cech wykazała, że niezależnie od gatunku, dekady i cech audio utworu, czynnikiem mającym największy wpływ na sukces utworu są metadane dotyczące wykonawcy (takie jak jego popularność i rozpoznawalność).

Jest to kolejne zjawisko typowe dla branży muzycznej. Wydany przez międzynarodową gwiazdę przeciętny utwór ma znacznie wyższe prawdopodobieństwo stania się światowym hitem niż wybitne dzieło niszowego artysty. Badane modele poprawnie zidentyfikowały tę zależność, marginalizując wpływ pozostałych cech utworu.

5.5. Rola czynników kontekstowych i socjologicznych

Główną przyczyną niskiej skuteczności modeli opartych jedynie na cechach audio jest całkowite pominięcie kontekstu socjologicznego i marketingowego. Na popularność muzyki wpływa szereg czynników zewnętrznych, które nie zostały uwzględnione w badanym zbiorze:

5.5.1. Ekspozycja medialna

Zbiór nie zawierał informacji o obecności utworu w mediach, radiu i telewizji, ani o wykorzystaniu go w filmach czy reklamach. Często to właśnie te czynniki decydują o tym, czy utwór stanie się popularny.

5.5.2. Analiza tekstowa i sentyment

Sam tytuł utworu lub nazwa albumu mogą wpływać na decyzję o jego odsłuchaniu. Włączenie do badań analizy sentymentu tekstów piosenek lub ich tytułów mogłoby dostarczyć dodatkowych informacji o ich potencjale komercyjnym.

5.5.3. Media społecznościowe

W roku 2011 media społecznościowe dopiero raczkowały. Współcześnie o popularności piosenek decydują algorytmy platform takich jak TikTok czy Instagram. Muzyka stała się tłem dla treści wizualnych generowanych przez użytkowników. Brak tych danych w modelu uniemożliwia analizę współczesnych mechanizmów powstawania hitów.

5.6. Wnioski

Podsumowując, przewidywanie popularności muzyki jest problemem rozległym i wielowymiarowym, znacznie wykraczającym poza podstawową inżynierię dźwięku. W celu maksymalizacji skuteczności systemów predykcyjnych niezbędna jest integracja cech akustycznych z danymi zewnętrznymi, obejmującymi aktywność w mediach społecznościowych, działania marketingowe oraz dynamikę trendów kulturowych.

6. Podsumowanie

Celem niniejszego projektu inżynierskiego było zbadanie możliwości predykcyjnych wybranych algorytmów maszynowego w kontekście przewidywania popularności utworów muzycznych. Podstawę badań stanowił zbiór danych *Million Song Dataset*, który poszerzono o dodatkowy zestaw *The Echo Nest Taste Profile Subset*, zawierający informacje o rzeczywistych odtworzeniach utworów przez użytkowników.

Proces badawczy obejmował wieloetapowe przetwarzanie danych: od wstępnej selekcji atrybutów i inżynierii cech (agregacja statystyk dla zmiennych wektorowych), przez eksploracyjną analizę danych (EDA), aż po właściwy preprocessing i kodowanie zmiennych celu. Badania przeprowadzono dwutorowo, definiując problem zarówno jako zadanie klasyfikacji (przypisanie utworu do jednej z czterech grup popularności), jak i regresji (predykcja zlogarytmowanej liczby odtworzeń).

Dla każdej ze strategii przetestowano skuteczność pięciu różnych algorytmów uczenia nadzorowanego:

- modele liniowe (Regresja Liniowa / Regresja Logistyczna),
- model oparty na drzewach decyzyjnych – *Random Forest*,
- model oparty na wektorach nośnych – SVM,
- model oparty na boostingu gradientowym – XGBoost,
- sztuczną sieć neuronową typu MLP (*Multi-Layer Perceptron*).

Zastosowano również metody zespołowe, łącząc predykcje modeli bazowych. Dla najbardziej obiecujących algorytmów (*Random Forest* oraz XGBoost) przeprowadzono optymalizację hiperparametrów z wykorzystaniem walidacji krzyżowej.

Przeprowadzone badania wykazały, że mimo zastosowania różnorodnych metod inżynierii danych i uczenia maszynowego, żaden z modeli nie osiągnął wysokiej precyzji predykcji. Najlepsze wyniki, niezależnie od sformułowanego problemu, uzyskał algorytm *Random Forest*, jednak nawet po strojeniu hiperparametrów jego skuteczność pozostała na umiarkowanym poziomie.

Szczegółowa analiza błędów pozwoliła na sformułowanie następujących obserwacji:

- **Wpływ niebalansowania danych:** Analiza macierzy pomyłek uwidoczniała, że modele mają tendencję do faworyzowania klasy większościowej, błędnie klasyfikując utwory z grup pośrednich i najważniejsze w analizie hity.
- **Spłaszczenie predykcji:** Wykresy rozrzutu dla zadania regresji wykazały, że modele „uśredniają wyniki”, całkowicie pomijając utwory o wysokiej popularności.
- **Niewystarczalność cech audio:** Potwierdzono, że surowe atrybuty akustyczne nie są wystarczające do wytłumaczenia zjawiska popularności. Najsilniejszym predyktorem okazały się metadane dotyczące rozpoznawalności artysty.

Wnioskiem płynącym z eksperymentu jest stwierdzenie, że popularność muzyki jest zjawiskiem złożonym i niemożliwym do analizy jedynie przy użyciu cech audio. Skuteczne systemy predykcyjne wymagałyby wzbogacenia danych o aspekty marketingowe, informacje o obecności piosenek w mediach publicznych i społecznościowych oraz czynniki socjologiczne.

Bibliografia


- [1] IFPI. *Global Music Report 2024 – State of the Industry*. Spraw. tech. International Federation of the Phonographic Industry, 2024.
- [2] Spotify Engineering. *Data Platform Explained Part I*. Spotify R&D Engineering Blog. [Dostęp online, 16.12.2025]. 2024.
- [3] Andrea Gao. „Catching the Earworm: Understanding Streaming Music Popularity Using Machine Learning Models”. W: *E3S Web of Conferences* 253 (2021). [2021 International Conference on Environmental and Engineering Management (EEM 2021)], s. 03024. DOI: [10.1051/e3sconf/202125303024](https://doi.org/10.1051/e3sconf/202125303024).
- [4] Shuo Jiang. „Predicting Music Popularity: A Machine Learning Approach Using Spotify Data”. W: *Proceedings of the 1st International Conference on Modern Logistics and Supply Chain Management (MLSCM 2024)*. SciTePress, 2024, s. 324–328. ISBN: 978-989-758-738-2. DOI: [10.5220/0013330000004558](https://doi.org/10.5220/0013330000004558).
- [5] Carlos V. S. Araujo, Marco A. P. Cristo i Rafael Giusti. „Predicting Music Popularity on Streaming Platforms”. W: *Proceedings of the 17th Brazilian Symposium on Computer Music (SBCM 2019)*. São João del-Rei, Brazil: Sociedade Brasileira de Computação (SBC), 2019, s. 141–148.
- [6] Yap Kah Yee i Mafas Raheem. „Predicting Music Popularity Using Spotify and YouTube Features”. W: *Indian Journal of Science and Technology* 15.36 (2022), s. 1786–1799. ISSN: 0974-5645. DOI: [10.17485/IJST/v15i36.2332](https://doi.org/10.17485/IJST/v15i36.2332).
- [7] Prashant Pareek i in. „Predicting Music Popularity Using Machine Learning Algorithm and Music Metrics Available in Spotify”. W: *Journal of Development Economics and Management Research Studies (JDMS)* 9.11 (2022), s. 10–19. ISSN: 2582-5119.
- [8] Spotify. *Spotify Developer Terms*. Spotify for Developers. [Dostęp online, 18.12.2025]. 2025.
- [9] Thierry Bertin-Mahieux i in. „The Million Song Dataset”. W: *Proceedings of the 12th International Conference on Music Information Retrieval (ISMIR 2011)*. Miami, FL, USA: University of Miami, 2011.
- [10] Tom M. Mitchell. *Machine Learning*. New York: McGraw-Hill, 1997. ISBN: 978-0070428072.
- [11] Ian Goodfellow, Yoshua Bengio i Aaron Courville. *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press, 2016.

- [12] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. New York: Springer, 2006. ISBN: 978-0387310732.
- [13] Douglas C. Montgomery, Elizabeth A. Peck i G. Geoffrey Vining. *Introduction to Linear Regression Analysis*. 6 wyd. Hoboken, NJ: Wiley, 2021.
- [14] Andreas C. Müller i Sarah Guido. *Introduction to Machine Learning with Python: A Guide for Data Scientists*. Sebastopol, CA: O'Reilly Media, 2016.
- [15] Gareth James i in. *An Introduction to Statistical Learning: with Applications in R*. T. 103. New York: Springer, 2013.
- [16] Trevor Hastie, Robert Tibshirani i Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2 wyd. Rozdział 9: Tree-Based Methods. New York: Springer, 2009.
- [17] Hasan Ahmed Salman, Ali Kalakech i Amani Steiti. „Random Forest Algorithm Overview”. W: *Babylonian Journal of Machine Learning* 2024 (2024), s. 69–79. DOI: 10.58496/BJML/2024/007.
- [18] Leo Breiman i in. *Classification and Regression Trees*. Boca Raton, FL: CRC Press, 1984.
- [19] Wei-Yin Loh. „Classification and regression trees”. W: *WIREs Data Mining and Knowledge Discovery* 1.1 (2011), s. 14–23. DOI: 10.1002/widm.8.
- [20] University of Minnesota Morris. *Classification & Regression Trees*. <https://mnstats.morris.umn.edu/multivariatestatistics/cart.html>. [Dostęp online: 29.12.2025].
- [21] Frontline Solvers. *Single Tree - Regression Tree Example*. <https://www.solver.com/xlminer/help/regression-tree-example>. [Dostęp online: 29.12.2025].
- [22] Alexey Natekin i Alois Knoll. „Gradient boosting machines, a tutorial”. W: *Frontiers in Neurobotics* (2013). ISSN: 1662-5218. DOI: 10.3389/fnbot.2013.00021.
- [23] Jerome H Friedman. „Greedy function approximation: A gradient boosting machine”. W: *Annals of statistics* (2001), s. 1189–1232.
- [24] Tianqi Chen i Carlos Guestrin. „XGBoost: A Scalable Tree Boosting System”. W: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM. New York, NY, USA, 2016, s. 785–794. DOI: 10.1145/2939672.2939785.
- [25] Darpan Pandey, Kamal Niwaria i Bharti Chourasia. „Machine Learning Algorithms: A Review”. W: *International Research Journal of Engineering and Technology (IRJET)* 6.2 (2019). ISSN: 2395-0056.
- [26] Chih-Wei Hsu i Chih-Jen Lin. „A Comparison of Methods for Multiclass Support Vector Machines”. W: *IEEE Transactions on Neural Networks* 13.2 (2002), s. 415–425. DOI: 10.1109/72.991427.
- [27] Corinna Cortes i Vladimir Vapnik. „Support-vector networks”. W: *Machine learning* 20.3 (1995), s. 273–297.


- [28] Larhmam. *SVM margin separation*. <https://commons.wikimedia.org/w/index.php?curid=73710028>. [Dostęp online: 27.12.2025, Licencja: CC BY-SA 4.0]. 2018.
- [29] Christopher JC Burges. „A tutorial on support vector machines for pattern recognition”. W: *Data mining and knowledge discovery 2.2* (1998), s. 121–167.
- [30] Harsh Kukreja i in. „An Introduction to Artificial Neural Network”. W: *International Journal of Advance Research and Innovative Ideas in Education (IJARIIE)* 2.1 (2016), s. 27–30. ISSN: 2395-4396.
- [31] P. Rogalewski. *AI dla każdego. Część 3*. <https://www.zabezpieczenia.com.pl/nowe-technologie/ai-dla-kazdego-czesc-3>. [Dostęp online: , data dostępu: 21.12.2025]. 2019.
- [32] Jaswinder Singh i Rajdeep Banerjee. „A Study on Single and Multi-layer Perceptron Neural Network”. W: *Proceedings of the Third International Conference on Computing Methodologies and Communication (ICCMC 2019)*. IEEE, 2019. ISBN: 978-1-5386-7808-4.
- [33] Simon Haykin. *Neural Networks and Learning Machines*. 3 wyd. Upper Saddle River, NJ: Pearson Education, 2009. ISBN: 978-0131471399.
- [34] David E. Rumelhart, Geoffrey E. Hinton i Ronald J. Williams. „Learning representations by back-propagating errors”. W: *Nature* 323.6088 (1986), s. 533–536.
- [35] David M W Powers. „Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation”. W: *Journal of Machine Learning Technologies* 2.1 (2011), s. 37–63.
- [36] Rob J Hyndman i George Athanasopoulos. *Forecasting: principles and practice*. 2 wyd. Melbourne, Australia: OTexts, 2018.
- [37] T Chai i RR Draxler. „Root mean square error (RMSE) or mean absolute error (MAE)? – Arguments against avoiding RMSE in the literature”. W: *Geoscientific Model Development* 7.3 (2014), s. 1247–1250.
- [38] The pandas development team. *pandas-dev/pandas: Pandas*. Wer. latest. 2024.
- [39] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt i in. *Array programming with NumPy*. 2020.
- [40] Andrew Collette. *h5py: HDF5 for Python*. 2013.
- [41] F. Pedregosa i in. „Scikit-learn: Machine Learning in Python”. W: *Journal of Machine Learning Research* 12 (2011), s. 2825–2830.
- [42] XGBoost Developers. *XGBoost Documentation*. <https://xgboost.readthedocs.io/>. Dostęp: 2025. 2025.
- [43] J. D. Hunter. „Matplotlib: A 2D graphics environment”. W: *Computing in Science & Engineering* 9.3 (2007), s. 90–95.
- [44] Michael Waskom. *seaborn: statistical data visualization*. Wer. 0.11.2. 2021.

- [45] The Echo Nest. *The Echo Nest Taste Profile Subset*. <http://millionsongdataset.com/tasteprofile/>. Dostęp: 2025-10-28. 2011.
- [46] Richard Erkhov. *The Million Song Dataset (Hugging Face Repository)*. https://huggingface.co/datasets/RichardErkhov/The_Million_Song_Dataset. Dostęp: 2025-10-30. 2023.
- [47] Thierry Bertin-Mahieux. *Example Track Description - Million Song Dataset*. <http://millionsongdataset.com/pages/example-track-description/>. Dostęp: 2025-11-5. 2011.
- [48] Oscar Celma. *Music Recommendation and Discovery: The Long Tail, Long Fail, and Long Play in the Digital Music Era*. Berlin, Heidelberg: Springer, 2010.
- [49] George Tzanetakis i Perry Cook. „Musical genre classification of audio signals”. W: *IEEE Transactions on speech and audio processing* 10.5 (2002), s. 293–302.
- [50] Earl Vickers. „The Loudness War: Background, Speculation and Recommendations”. W: *Proceedings of the 129th Audio Engineering Society Convention*. 8175. San Francisco, CA, USA: Audio Engineering Society, 2010.

A. Powiększone wizualizacje macierzy korelacji



Rys. A.1. Powiększona macierz korelacji przed selekcją cech.



Rys. A.2. Powiększona macierz korelacji po po usunięciu skorelowanych zmiennych.